Prédire l'atterrissage du premier étage du Falcon 9

Rapport de Projet de Capstone en Science des Données — IBM Data Science

Penda Vanessa — 19 octobre 2026

Dépôt GitHub (tous les notebooks et le fichier Python) : https://github.com/vanessapenda/Spacex-Capstone

OUTLINE

Plan

1

Résumé exécutif

Executive Summary

2

Introduction

Introduction

3

Méthodologie

Data collection, wrangling, EDA, visual analytics, ML

4

Résultats EDA

Visualisation et SQL

5

Analytique interactive

Folium et Plotly Dash

6

Analyse prédictive et conclusion

Classification, Conclusion

Projet GitHub : https://github.com/vanessapenda/Spacex-Capstone

EXECUTIVE SUMMARY

Résumé exécutif

Méthodes utilisées

- **Collecte :** API REST SpaceX et web scraping de Wikipedia
- **Préparation :** filtrage Falcon 9, valeurs manquantes, création de la cible Class
- **EDA :** graphiques Matplotlib/Seaborn et 10 requêtes SQL
- **Analytique interactive :** carte Folium et dashboard Plotly Dash
- **Prédiction :** régression logistique, SVM, arbre de décision, KNN (GridSearchCV, cv = 10)

Résultats clés

66,7 %
taux d'atterrissage réussi (90 vols)

90 %
de succès en 2019 (0 % avant 2014)

76,9 %
de succès à KSC LC-39A, le meilleur site

86,3 %
arbre de décision, meilleur modèle (83,3 % sur le test)

GitHub : https://github.com/vanessapenda/Spacex-Capstone

Introduction

Contexte

SpaceX vend ses lancements Falcon 9 environ 62 millions de dollars, contre plus de 165 millions chez les concurrents, car le premier étage est réutilisé.

Si l'on prédit l'atterrissage du premier étage, on peut estimer le coût d'un lancement. Une entreprise concurrente (Space Y) peut ainsi mieux répondre aux appels d'offres.

Problèmes à résoudre

1. Quels facteurs (charge utile, site, orbite, nombre de vols, booster) influencent le succès de l'atterrissage ?
2. Comment le taux de succès évolue-t-il dans le temps ?
3. Quel modèle de classification prédit le mieux l'atterrissage ?

Projet GitHub : https://github.com/vanessapenda/Spacex-Capstone

METHODOLOGY

Méthodologie

1. **Collecte des données** API REST SpaceX et web scraping Wikipedia
2. **Préparation (data wrangling)** Filtrage Falcon 9, valeurs manquantes, cible Class (1 = succès)
3. **EDA** Visualisations (dispersion, barres, courbe) et requêtes SQL
4. **Analytique visuelle interactive** Carte Folium et dashboard Plotly Dash
5. **Analyse prédictive** Standardisation, split 80/20, GridSearchCV sur 4 modèles, précision et matrice de confusion

GitHub : https://github.com/vanessapenda/Spacex-Capstone

Collecte des données — API SpaceX

1. **Requête GET**
   api.spacexdata.com/v4/launches/past
2. **Conversion**
   response.json() puis pd.json_normalize()
3. **Nettoyage**
   1 booster et 1 charge utile par lancement, dates ≤ 13/11/2020
4. **Enrichissement**
   appels aux endpoints rockets, launchpads, payloads, cores
5. **Construction**
   dictionnaire launch_dict → DataFrame
6. **Filtrage**
   Falcon 9 seulement, PayloadMass manquante remplacée par la moyenne

Fonctions d'appel API

- getBoosterVersion() → nom du booster
- getLaunchSite() → site, latitude, longitude
- getPayloadData() → masse, orbite
- getCoreData() → bloc, réutilisations, résultat d'atterrissage

GitHub : https://github.com/vanessapenda/Spacex-Capstone/blob/main/jupyter-labs-spacex-data-collection-api.ipynb

Collecte des données — Web scraping

1. **Requête HTTP**
   requests.get() sur la page Wikipedia « List of Falcon 9 and Falcon Heavy launches »
2. **Analyse HTML**
   objet BeautifulSoup
3. **Sélection**
   soup.find_all('table') et choix du tableau des lancements
4. **Colonnes**
   extraction des en-têtes <th>
5. **Remplissage**
   parcours des lignes <tr> vers un dictionnaire
6. **Export**
   DataFrame puis fichier CSV

121

lancements extraits

8

colonnes : Flight No., Date, Launch site, Payload, Payload mass, Orbit, Customer, Launch outcome

GitHub : https://github.com/vanessapenda/Spacex-Capstone/blob/main/jupyter-labs-webscraping.ipynb

Préparation des données

1. **Valeurs manquantes**
   pourcentage de valeurs nulles par colonne
2. **Exploration**
   lancements par site, par orbite, et types de résultats
3. **Mauvais résultats**
   False ASDS, False Ocean, False RTLS, None ASDS, None None
4. **Variable cible**
   Class = 0 si mauvais résultat, sinon 1
5. **Taux de succès**
   moyenne de Class = 66,7 %

Outcome	Nombre	Class
True ASDS	41	1
None None	19	0
True RTLS	14	1
False ASDS	6	0
True Ocean	5	1
False Ocean	2	0
None ASDS	2	0
False RTLS	1	0

GitHub : https://github.com/vanessapenda/Spacex-Capstone/blob/main/labs-jupyter-spacex-data-wrangling.ipynb

EDA avec visualisation des données

Graphique	Variables	Objectif
Dispersion	Numéro de vol × charge utile ; × site ; × orbite	Effet de l'expérience sur le succès
Dispersion	Charge utile × site ; × orbite	Limites de charge et effet de la masse
Barres	Taux de succès par orbite	Comparer la difficulté des orbites
Courbe	Taux de succès moyen par année	Tendance dans le temps

Ingénierie des variables : encodage one-hot de Orbit, LaunchSite, LandingPad et Serial. On obtient 83 variables pour le Machine Learning.

GitHub : https://github.com/vanessapenda/Spacex-Capstone/blob/main/edadataviz.ipynb

EDA avec SQL

1. Sites de lancement uniques
2. 5 lancements de sites « CCA% »
3. Masse totale pour NASA (CRS)
4. Masse moyenne du F9 v1.1
5. 1er atterrissage réussi au sol
6. Succès sur barge, 4 000 à 6 000 kg
7. Missions réussies / échouées
8. Boosters à charge maximale
9. Échecs sur barge en 2015
10. Classement des résultats 2010-2017

Données chargées dans SQLite (table SPACEXTBL), requêtes exécutées avec %%sql.

GitHub : https://github.com/vanessapenda/Spacex-Capstone/blob/main/jupyter-labs-eda-sql-coursera_sqllite.ipynb

Analytique visuelle interactive

Carte Folium

- **Circle + Marker :** les 4 sites de lancement
- **MarkerCluster :** marqueurs verts (succès) et rouges (échecs)
- **MousePosition :** coordonnées des points proches
- **PolyLine :** distances à la côte et aux routes

Dashboard Plotly Dash

- **Dropdown :** tous les sites ou un site
- **Pie chart :** succès par site, ou succès / échecs d'un site
- **RangeSlider :** charge utile de 0 à 10 000 kg
- **Scatter :** charge utile × résultat, couleur = booster

Pourquoi : visualiser la géographie des sites et comparer les sites et charges utiles de façon interactive.

GitHub : https://github.com/vanessapenda/Spacex-Capstone/blob/main/lab_jupyter_launch_site_location.ipynb

GitHub : https://github.com/vanessapenda/Spacex-Capstone/blob/main/spacex-dash-app.py

Analyse prédictive (classification)

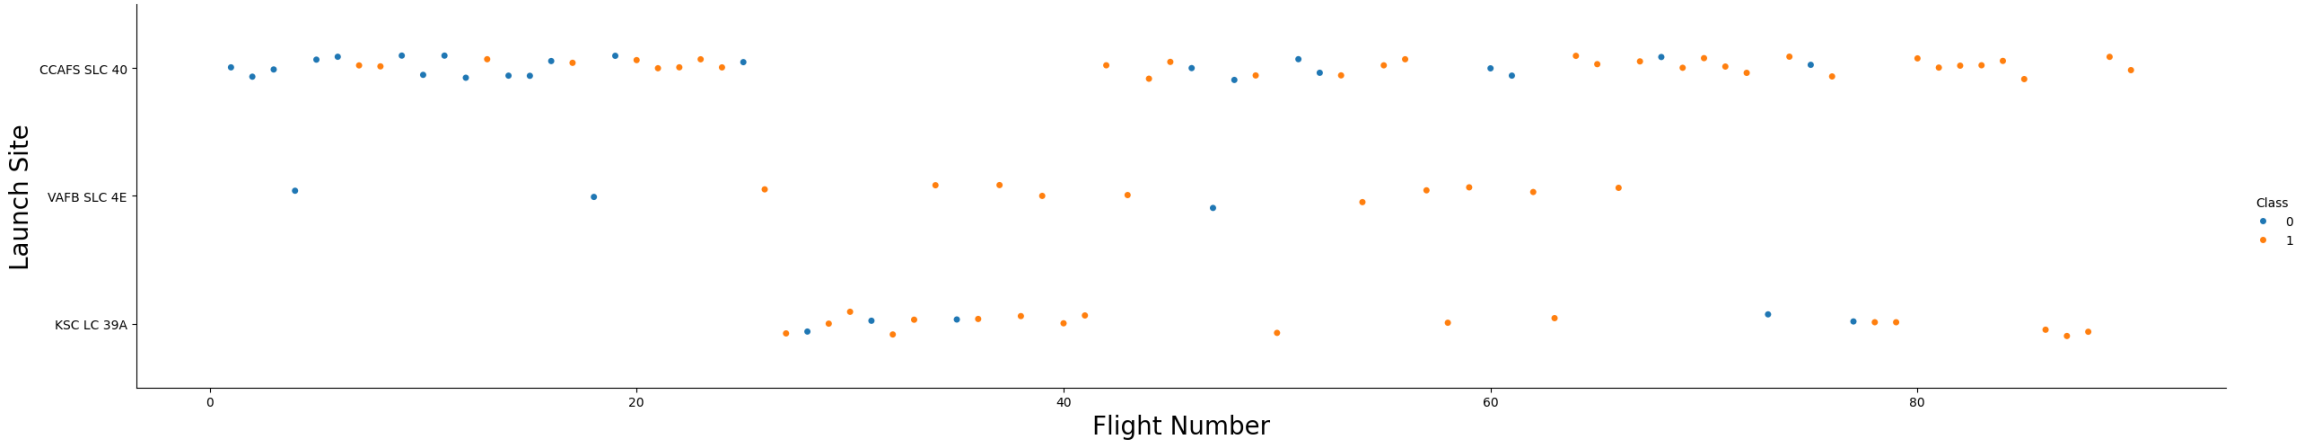
1. **Préparation**
   Y = Class ; X = 83 variables standardisées (StandardScaler)
2. **Découpage**
   train_test_split 80/20 (18 vols de test), random_state = 2
3. **Optimisation**
   GridSearchCV, validation croisée à 10 plis
4. **Modèles**
   régression logistique, SVM, arbre de décision, KNN
5. **Évaluation et choix**
   précision sur le test, matrice de confusion, meilleur score

Hyperparamètres testés

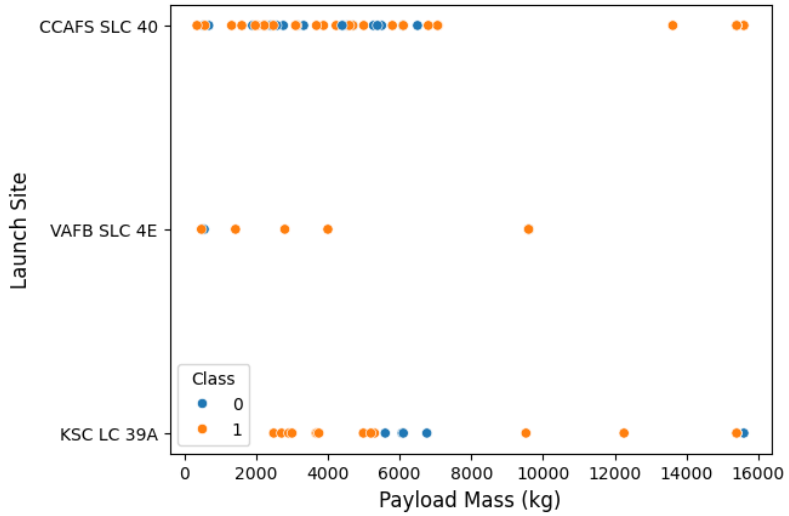
- **Régression logistique :** C, penalty, solver
- **SVM :** kernel, C, gamma
- **Arbre :** criterion, splitter, max_depth…
- **KNN :** n_neighbors, algorithm, p

GitHub : https://github.com/vanessapenda/Spacex-Capstone/blob/main/SpaceX_Machine_Learning_Prediction_Part_5.ipynb

Résultats EDA — sites de lancement



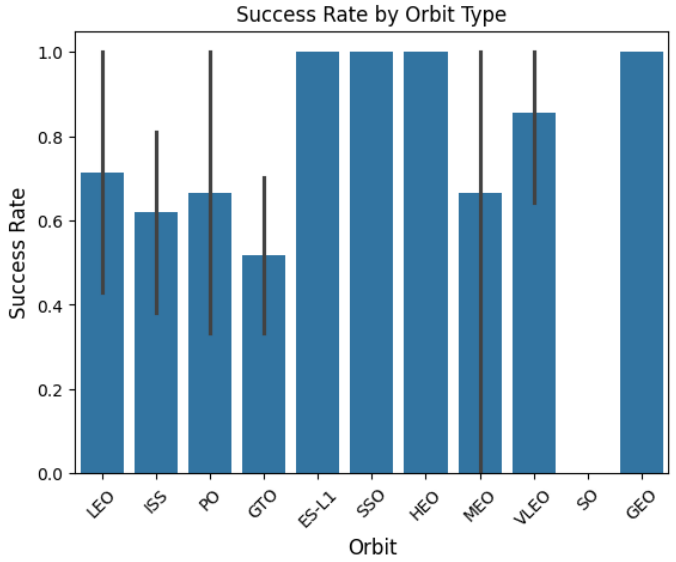
Numéro de vol × site de lancement (orange = succès)



- Les premiers vols (CCAFS SLC 40) échouent surtout ; le succès augmente avec le numéro de vol sur tous les sites
- CCAFS SLC 40 est le site le plus utilisé (55 lancements sur 90)
- Charge utile × site : VAFB SLC 4E n'a aucun lancement au-delà de 10 000 kg ; les charges lourdes réussissent presque toujours

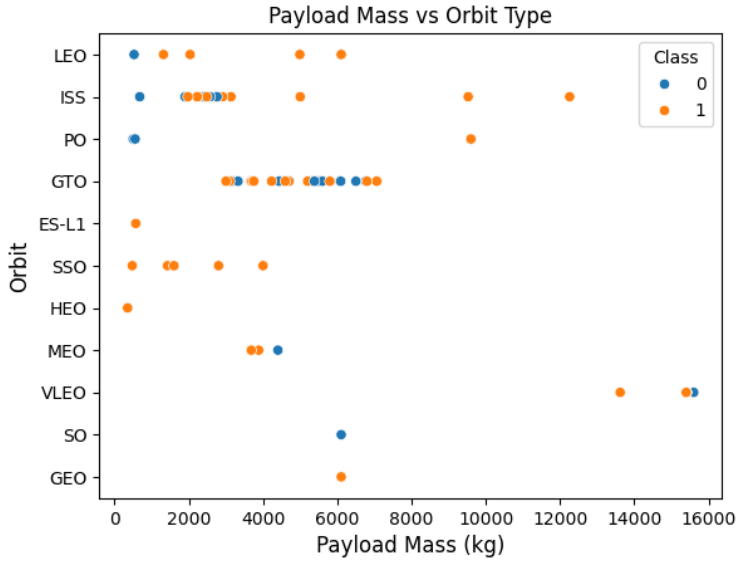
Projet GitHub : https://github.com/vanessapenda/Spacex-Capstone

Résultats EDA — orbites



Graphique à barres : taux de succès par orbite

- ES-L1, GEO, HEO, SSO : 100 % (1 à 5 lancements)
- VLEO : 85,7 % sur 14 lancements
- GTO : 51,9 % sur 27, l'orbite la plus difficile

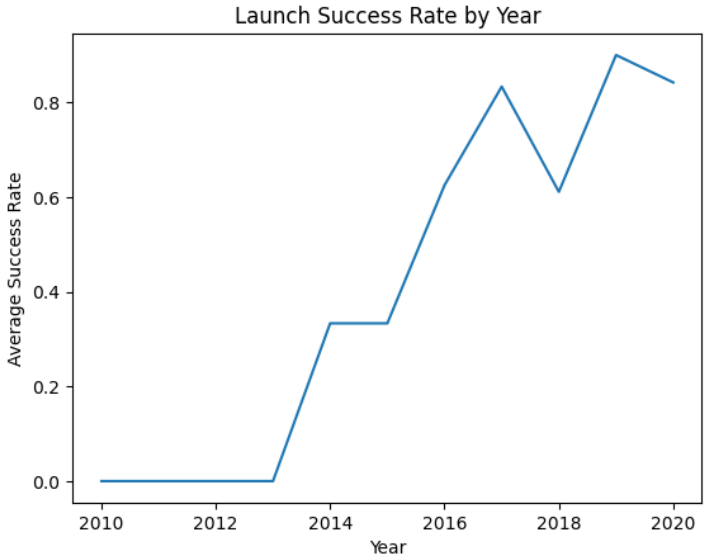


Dispersion : charge utile × orbite

- Charges lourdes : plus de succès en PO, LEO et ISS
- GTO : succès et échecs mélangés quelle que soit la masse

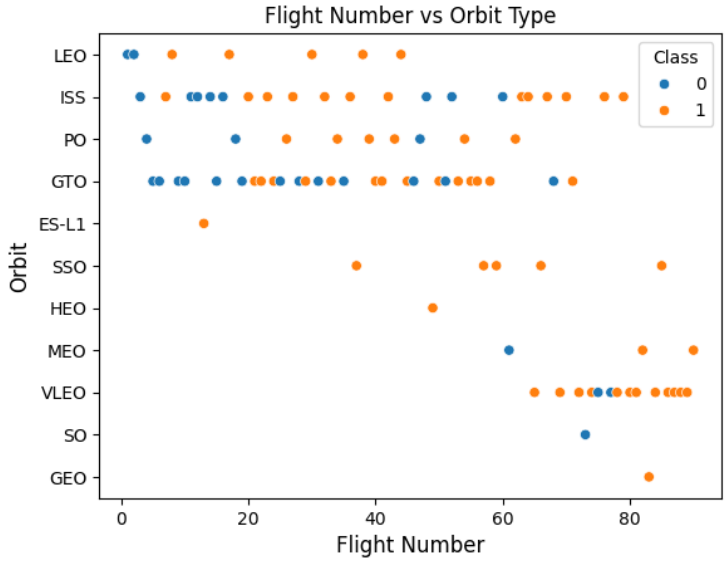
Projet GitHub : https://github.com/vanessapenda/Spacex-Capstone

Résultats EDA — tendance annuelle



Courbe : taux de succès moyen par année

- 0 % de 2010 à 2013, puis hausse continue
- 83 % en 2017, baisse en 2018 (61 %), pic à 90 % en 2019



Dispersion : numéro de vol × orbite

- En LEO, le succès suit le nombre de vols
- En GTO, pas de lien clair ; VLEO récent et réussi

Projet GitHub : https://github.com/vanessapenda/Spacex-Capstone

Résultats EDA avec SQL (1/3)

Tâche 1 — Sites de lancement

```
SELECT DISTINCT "Launch_Site"
FROM SPACEXTBL;
```

Résultat : CCAFS LC-40, VAFB SLC-4E, KSC LC-39A, CCAFS SLC-40 (4 sites)

Tâche 2 — Sites commençant par « CCA »

```
SELECT * FROM SPACEXTBL
WHERE "Launch_Site" LIKE 'CCA%'
LIMIT 5;
```

Résultat : 5 vols de 2010 à 2013 depuis CCAFS LC-40, boosters F9 v1.0, charges de 0 à 677 kg

Tâche 3 — Masse totale NASA (CRS)

```
SELECT SUM("PAYLOAD_MASS__KG_")
FROM SPACEXTBL
WHERE "Customer" = 'NASA (CRS)';
```

Résultat : 45 596 kg

Tâche 4 — Masse moyenne F9 v1.1

```
SELECT AVG("PAYLOAD_MASS__KG_")
FROM SPACEXTBL
WHERE "Booster_Version" = 'F9 v1.1';
```

Résultat : 2 928,4 kg

Projet GitHub : https://github.com/vanessapenda/Spacex-Capstone

Résultats EDA avec SQL (2/3)

Tâche 5 — Premier succès au sol

```
SELECT MIN(Date) FROM SPACEXTBL
WHERE "Landing_Outcome" =
  'Success (ground pad)';
```

Résultat : 22/12/2015, premier atterrissage réussi sur plateforme au sol

Tâche 6 — Succès sur barge, 4 000 à 6 000 kg

```
SELECT DISTINCT "Booster_Version"
FROM SPACEXTBL WHERE "Landing_Outcome"
  = 'Success (drone ship)'
AND "PAYLOAD_MASS__KG_" > 4000
AND "PAYLOAD_MASS__KG_" < 6000;
```

Résultat : F9 FT B1022, F9 FT B1026, F9 FT B1021.2, F9 FT B1031.2

Tâche 7 — Missions réussies et échouées

```
SELECT "Mission_Outcome", COUNT(*)
FROM SPACEXTBL
GROUP BY "Mission_Outcome";
```

Résultat : 100 succès (98 + 1 + 1 « payload status unclear ») et 1 échec en vol

Ce que l'on retient

- Les missions réussissent presque toujours (99 %)
- La vraie difficulté est l'atterrissage du premier étage
- Le premier succès au sol date de fin 2015

Projet GitHub : https://github.com/vanessapenda/Spacex-Capstone

Résultats EDA avec SQL (3/3)

Tâche 8 — Boosters à charge maximale

```
SELECT "Booster_Version" FROM SPACEXTBL
WHERE "PAYLOAD_MASS__KG_" =
 (SELECT MAX("PAYLOAD_MASS__KG_")
  FROM SPACEXTBL);
```

Résultat : 12 boosters F9 B5 (Block 5), dont B1048.4, B1049.4, B1051.3, B1056.4, B1060.2

Tâche 9 — Échecs sur barge en 2015

```
SELECT substr(Date,6,2) AS month, ...
FROM SPACEXTBL
WHERE substr(Date,0,5) = '2015'
AND "Landing_Outcome"='Failure (drone ship)';
```

Résultat : Janvier : F9 v1.1 B1012 ; avril : F9 v1.1 B1015, tous deux à CCAFS LC-40

Tâche 10 — Classement 2010-06-04 → 2017-03-20

```
SELECT "Landing_Outcome", COUNT(*) AS n
FROM SPACEXTBL WHERE Date BETWEEN ...
GROUP BY "Landing_Outcome"
ORDER BY n DESC;
```

Résultat : No attempt 10, Success (drone ship) 5, Failure (drone ship) 5, Success (ground pad) 3, Controlled (ocean) 3…

Analyse temporelle

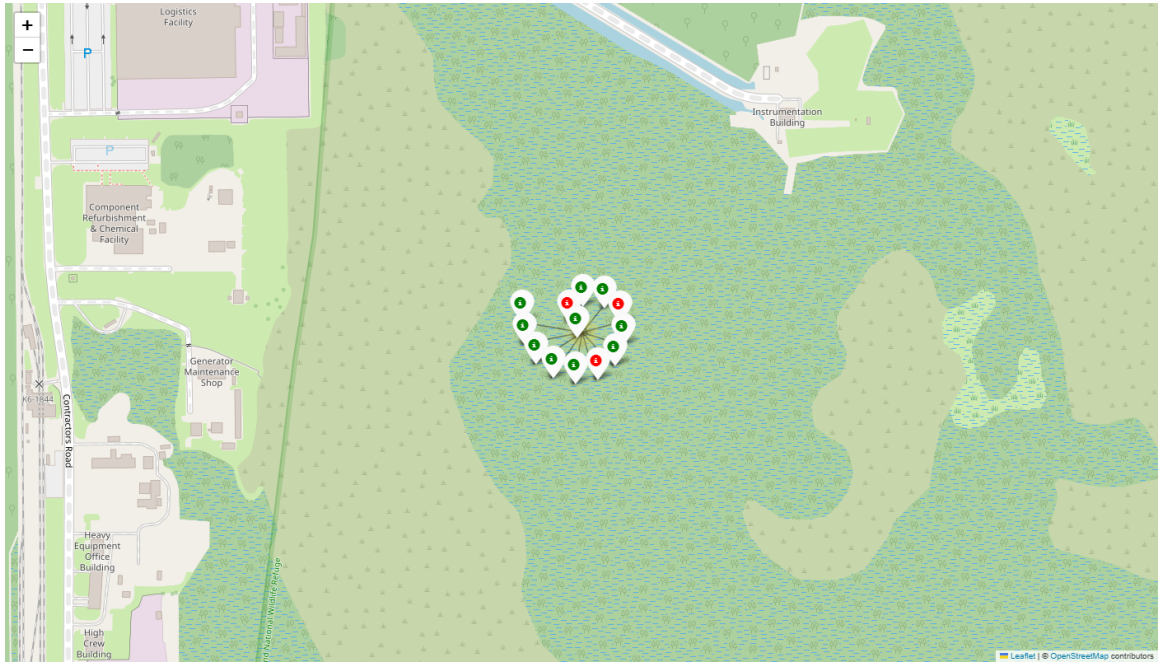
- Avant 2017, l'absence de tentative domine
- Sur barge : autant de succès que d'échecs (5 / 5)
- Les charges maximales sont portées par la version la plus récente (B5)

Projet GitHub : https://github.com/vanessapenda/Spacex-Capstone

Carte Folium — sites et résultats des lancements



Les 4 sites : 3 en Floride, 1 en Californie, tous en bord de mer



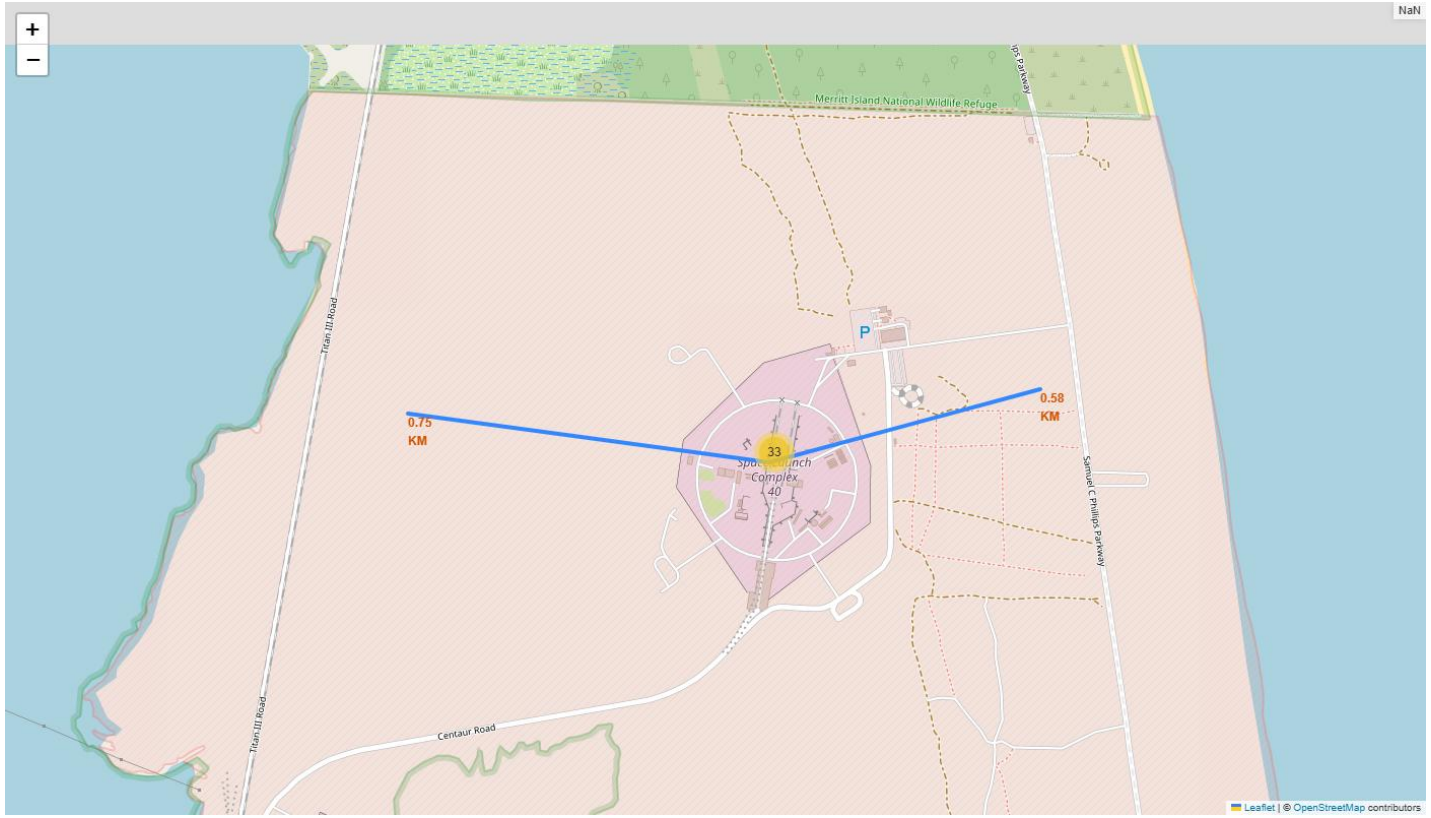
KSC LC-39A : 10 marqueurs verts (succès), 3 rouges (échecs)

Site	KSC LC-39A	CCAFS SLC-40	VAFB SLC-4E	CCAFS LC-40
Taux de succès	76,9 % (10/13)	42,9 % (3/7)	40,0 % (4/10)	26,9 % (7/26)

Projet GitHub : https://github.com/vanessapenda/Spacex-Capstone

FOLIUM MAP – PROXIMITY ANALYSIS

Carte Folium — analyse de proximité



CCAFS SLC-40 : lignes PolyLine, distances calculées avec la formule de Haversine

0,58 km
jusqu'à la côte

0,75 km
jusqu'à une route

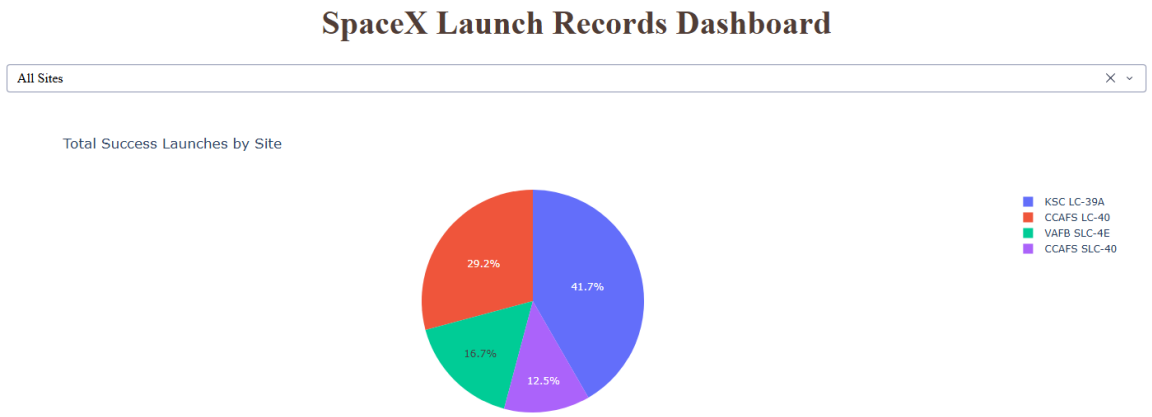
23 km
jusqu'à Titusville

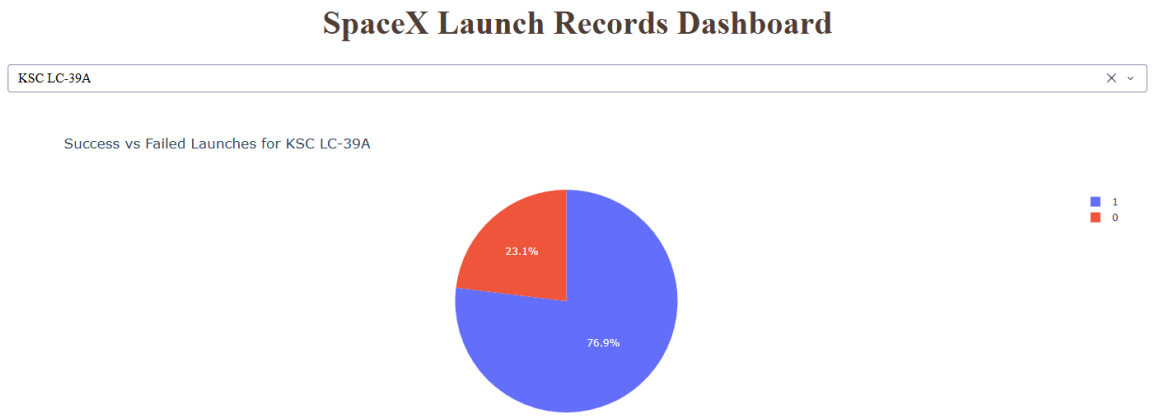
78 km
jusqu'à Orlando

Les sites sont proches de la côte et des routes (logistique) mais loin des villes, pour la sécurité.

Projet GitHub : https://github.com/vanessapenda/Spacex-Capstone

Dashboard Plotly Dash — graphiques à secteurs

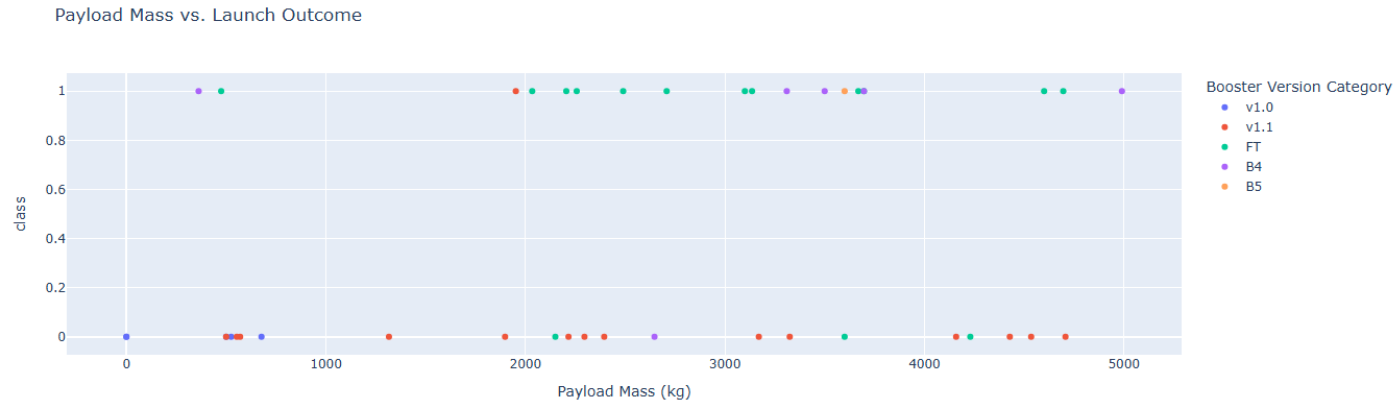




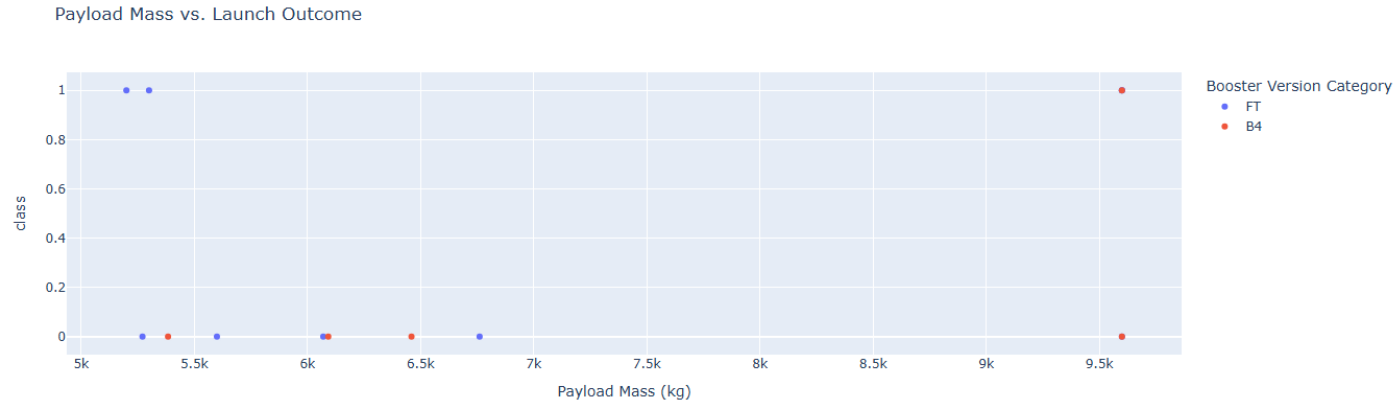
- **Tous les sites :** KSC LC-39A représente 41,7 % des succès, devant CCAFS LC-40 (29,2 %), VAFB SLC-4E (16,7 %) et CCAFS SLC-40 (12,5 %)
- **KSC LC-39A :** 76,9 % de succès (10 sur 13) contre 23,1 % d'échecs, le meilleur taux de tous les sites

Projet GitHub : https://github.com/vanessapenda/Spacex-Capstone

Dashboard Plotly Dash — charge utile × résultat



Curseur 0 – 5 000 kg



Curseur 5 000 – 10 000 kg

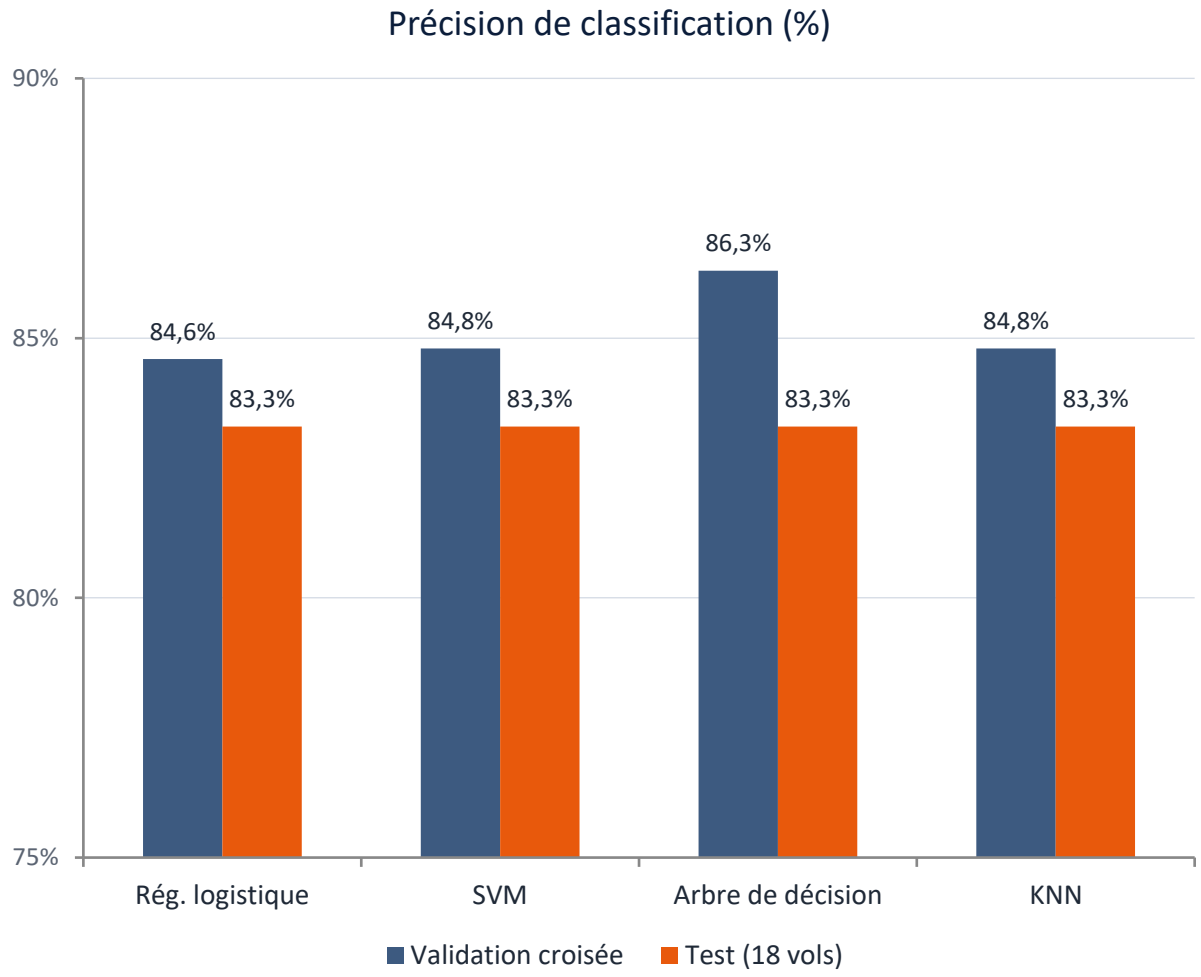
Charge utile	Succès
0 – 2 000 kg	23 %
2 000 – 4 000 kg	62 %
4 000 – 6 000 kg	38 %
6 000 – 10 000 kg	33 %

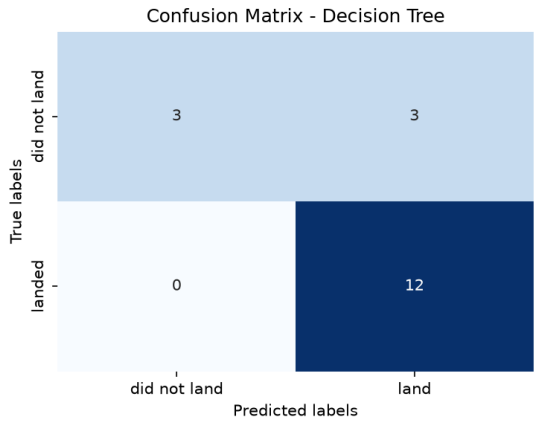
Ce que l'on observe

- 2 000 à 4 000 kg : meilleur taux de succès
- Booster FT : 67 % sur 24 vols ; v1.1 : 7 % sur 15

Projet GitHub : https://github.com/vanessapenda/Spacex-Capstone

Résultats de l'analyse prédictive





Matrice de confusion — arbre de décision

12 vrais positifs, 3 vrais négatifs, 3 faux positifs, 0 faux négatif

Meilleur modèle : arbre de décision

- Meilleure validation croisée : 86,3 % (max_depth = 6, gini)
- 83,3 % sur le test, comme les 3 autres modèles
- Il prédit tous les succès ; sa faiblesse : 3 faux positifs

Projet GitHub : https://github.com/vanessapenda/Spacex-Capstone

Conclusion

- **Expérience :** le taux de succès passe de 0 % (2010-2013) à 90 % (2019)
- **Site :** KSC LC-39A est le plus performant (76,9 %) ; tous les sites sont près des côtes et loin des villes
- **Orbite :** ES-L1, GEO, HEO, SSO, VLEO réussissent le mieux ; GTO est la plus difficile (52 %)
- **Charge utile :** 2 000 à 4 000 kg est la plage la plus favorable ; le booster FT surpasse les anciennes versions
- **Modèle :** l'arbre de décision est retenu (86,3 % en validation croisée, 83,3 % sur le test) pour estimer le coût d'un lancement

Idées créatives et innovantes

- **Outil d'enchère pour Space Y :** coût estimé = probabilité d'atterrissage × économie de réutilisation
- **Plus de données :** vols après 2020, météo, réutilisations
- **Modèles plus robustes :** forêt aléatoire, XGBoost, F1 et ROC-AUC
- **Prédiction en direct :** intégrer le modèle au dashboard Dash

Projet GitHub : https://github.com/vanessapenda/Spacex-Capstone