Prédire l'atterrissage du premier étage du Falcon 9

Projet Capstone — IBM Data Science Professional Certificate

Penda Vanessa

19 octobre 2026

Plan

1

Résumé exécutif

Méthodes et résultats clés

2

Introduction

Contexte et questions

3

Méthodologie

Collecte, préparation, EDA, ML

4

Résultats

EDA, cartes, dashboard, modèles

5

Conclusion

Enseignements et idées

6

Annexe

Graphiques complémentaires

Résumé exécutif

Méthodes utilisées

- **Collecte :** API REST SpaceX et web scraping de Wikipedia
- **Préparation :** filtrage Falcon 9, valeurs manquantes, création de la cible Class
- **EDA :** graphiques Matplotlib/Seaborn et requêtes SQL (SQLite)
- **Analytique interactive :** carte Folium et dashboard Plotly Dash
- **Prédiction :** régression logistique, SVM, arbre de décision, KNN optimisés par GridSearchCV (cv = 10)

Résultats clés

66,7 %
taux d'atterrissage réussi (90 vols)

90 %
taux de succès en 2019 (0 % avant 2014)

76,9 %
succès au site KSC LC-39A, le meilleur

83,3 %
précision sur le test ; arbre de décision retenu

Introduction

Contexte

SpaceX propose des lancements Falcon 9 à environ 62 millions de dollars, contre plus de 165 millions chez les concurrents. L'essentiel de cette économie vient de la réutilisation du premier étage, qui revient se poser sur une barge ou une plateforme au sol.

Si l'on sait prédire l'atterrissage du premier étage, on peut estimer le coût d'un lancement. Cette information est précieuse pour une entreprise concurrente (Space Y) qui veut répondre aux mêmes appels d'offres.

Questions étudiées

1. Quels facteurs (charge utile, site, orbite, nombre de vols, version du booster) influencent le succès de l'atterrissage ?
2. Comment le taux de succès évolue-t-il dans le temps ?
3. Quel modèle de classification prédit le mieux l'atterrissage ?

Section 1

Méthodologie

Résumé de la méthodologie

1. **Collecte des données** API REST SpaceX (lancements passés) et web scraping de la page Wikipedia des lancements Falcon 9

2. **Préparation des données** Filtrage Falcon 9, remplacement des charges utiles manquantes par la moyenne, création de la cible Class (1 = atterrissage réussi)

3. **Analyse exploratoire (EDA)** Visualisations (nuages de points, barres, courbe) et requêtes SQL

4. **Analytique visuelle interactive** Carte Folium des sites et des résultats, dashboard Plotly Dash

5. **Analyse prédictive** Standardisation, découpage 80/20, GridSearchCV sur 4 modèles, évaluation par précision et matrice de confusion

Collecte des données — API SpaceX

1. **Requête GET**
   api.spacexdata.com/v4/launches/past (copie JSON statique fournie par IBM)
2. **Conversion**
   response.json() puis pd.json_normalize() en DataFrame
3. **Nettoyage initial**
   un seul booster et une seule charge utile par lancement, dates jusqu'au 13/11/2020
4. **Enrichissement**
   appels aux endpoints rockets, launchpads, payloads et cores
5. **Construction**
   dictionnaire launch_dict puis DataFrame launch_df
6. **Filtrage**
   on garde uniquement les Falcon 9 et on remplace les PayloadMass manquantes par la moyenne

Fonctions d'appel API

- getBoosterVersion() → nom du booster
- getLaunchSite() → site, latitude, longitude
- getPayloadData() → masse, orbite
- getCoreData() → bloc, réutilisations, résultat d'atterrissage, pieds, ailerons

GitHub : https://github.com/VOTRE-NOM/spacex-capstone/blob/main/jupyter-labs-spacex-data-collection-api.ipynb

Collecte des données — Web scraping

1. **Requête HTTP**
   requests.get() sur la page Wikipedia « List of Falcon 9 and Falcon Heavy launches » (statut 200)
2. **Analyse HTML**
   création d'un objet BeautifulSoup
3. **Sélection des tableaux**
   soup.find_all('table') et choix du tableau des lancements
4. **Noms de colonnes**
   extraction des en-têtes <th>
5. **Remplissage**
   parcours de chaque ligne <tr> et ajout dans un dictionnaire
6. **Export**
   conversion en DataFrame puis enregistrement en CSV

121

lancements extraits

8

colonnes : Flight No., Date, Launch site, Payload, Payload mass, Orbit, Customer, Launch outcome

GitHub : https://github.com/VOTRE-NOM/spacex-capstone/blob/main/jupyter-labs-webscraping.ipynb

Préparation des données (data wrangling)

1. **Valeurs manquantes**
   calcul du pourcentage de valeurs nulles par colonne
2. **Exploration**
   lancements par site, par orbite, et types de résultats d'atterrissage
3. **Mauvais résultats**
   False ASDS, False Ocean, False RTLS, None ASDS, None None
4. **Variable cible**
   Class = 0 si mauvais résultat, sinon 1
5. **Taux de succès**
   moyenne de Class

Résultats d'atterrissage (Outcome)

Outcome	Nombre	Class
True ASDS	41	1
None None	19	0
True RTLS	14	1
False ASDS	6	0
True Ocean	5	1
False Ocean	2	0
None ASDS	2	0
False RTLS	1	0

Taux de succès global : 66,7 %

GitHub : https://github.com/VOTRE-NOM/spacex-capstone/blob/main/labs-jupyter-spacex-data-wrangling.ipynb

EDA avec visualisation des données

Graphique	Variables	Objectif
Nuage de points	Numéro de vol × masse de la charge utile	Voir si l'expérience et la masse influencent l'atterrissage
Nuage de points	Numéro de vol × site de lancement	Suivre le succès de chaque site dans le temps
Nuage de points	Masse de la charge utile × site	Repérer les limites de charge par site
Diagramme à barres	Taux de succès par orbite	Comparer la difficulté des orbites
Nuage de points	Numéro de vol × orbite	Lien entre expérience et orbite
Nuage de points	Masse de la charge utile × orbite	Lien entre masse et orbite
Courbe	Taux de succès moyen par année	Mesurer la tendance dans le temps

Ingénierie des variables : encodage one-hot de Orbit, LaunchSite, LandingPad et Serial, puis conversion en float64. On obtient 83 variables pour le Machine Learning.

GitHub : https://github.com/VOTRE-NOM/spacex-capstone/blob/main/edadataviz.ipynb

EDA avec SQL

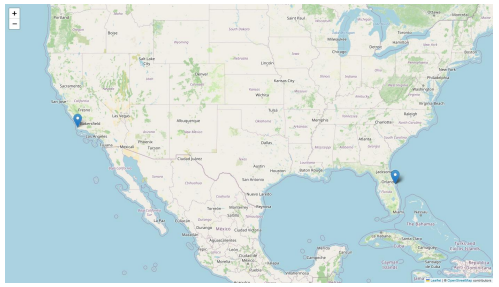
1. Noms uniques des sites de lancement
2. 5 lancements dont le site commence par « CCA »
3. Masse totale transportée pour la NASA (CRS)
4. Masse moyenne pour le booster F9 v1.1
5. Date du premier atterrissage réussi sur plateforme au sol
6. Boosters réussis sur barge avec une charge de 4 000 à 6 000 kg
7. Nombre total de missions réussies et échouées
8. Boosters ayant porté la charge maximale (sous-requête)
9. Échecs sur barge en 2015 : mois, booster, site
10. Classement des résultats d'atterrissage entre 2010-06-04 et 2017-03-20

Les données sont chargées dans SQLite (table SPACEXTBL) et interrogées avec %%sql dans Jupyter.

GitHub : https://github.com/VOTRE-NOM/spacex-capstone/blob/main/jupyter-labs-eda-sql-coursera_sqllite.ipynb

Carte interactive avec Folium

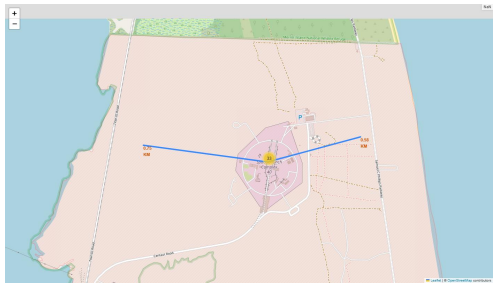
Objet ajouté	Ce qu'il montre	Pourquoi
folium.Circle + Marker	Les 4 sites de lancement (et le Johnson Space Center de la NASA)	Localiser les sites et voir leur position géographique
MarkerCluster + marqueurs vert/rouge	Le résultat de chaque lancement (vert = succès, rouge = échec)	Comparer visuellement le taux de succès des sites
MousePosition	Les coordonnées sous le curseur	Trouver les points d'intérêt proches d'un site
PolyLine + marqueur de distance	Distance d'un site à la côte et à une route	Étudier l'environnement immédiat des sites



Sites de lancement



Succès / échecs

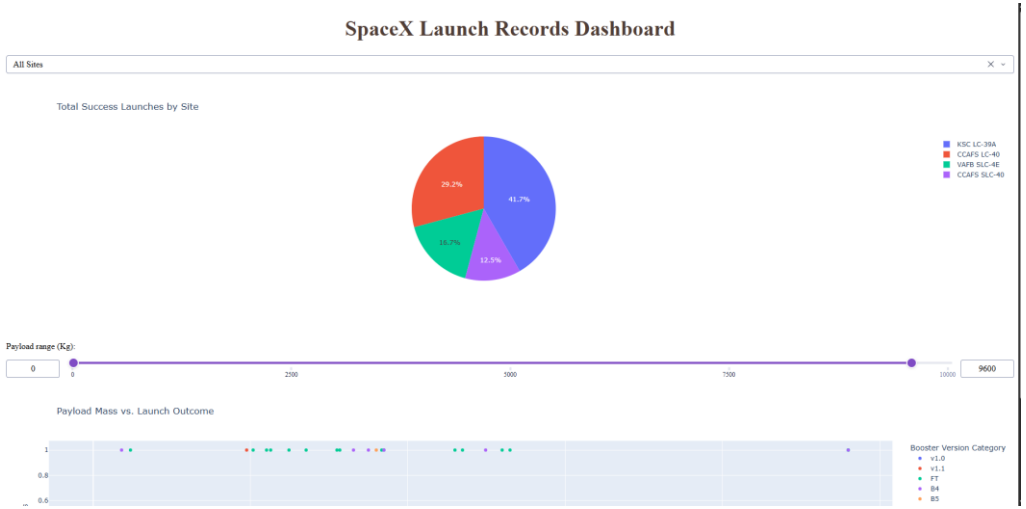


Distances

GitHub : https://github.com/VOTRE-NOM/spacex-capstone/blob/main/lab_jupyter_launch_site_location.ipynb

Dashboard avec Plotly Dash

Composant	Rôle
Liste déroulante (Dropdown)	Choisir tous les sites ou un site précis
Camembert (Pie chart)	Part des succès par site, ou succès / échecs d'un site
Curseur de plage (RangeSlider)	Filtrer la charge utile entre 0 et 10 000 kg
Nuage de points (Scatter)	Charge utile × résultat, couleur selon la version du booster



Pourquoi : les deux callbacks mettent à jour les graphiques en direct. On peut ainsi comparer les sites et repérer les plages de charge utile qui réussissent le mieux.

GitHub : https://github.com/VOTRE-NOM/spacex-capstone/blob/main/spacex-dash-app.py

Analyse prédictive (classification)

1. **Préparation**
   Y = Class ; X = 83 variables standardisées (StandardScaler)
2. **Découpage**
   train_test_split, 80 % entraînement / 20 % test (18 vols), random_state = 2
3. **Optimisation**
   GridSearchCV avec validation croisée à 10 plis pour chaque modèle
4. **Modèles**
   régression logistique, SVM, arbre de décision, KNN
5. **Évaluation**
   précision sur le test et matrice de confusion
6. **Choix**
   le modèle avec la meilleure précision de validation croisée

Hyperparamètres testés

- **Régression logistique :** C, penalty, solver
- **SVM :** kernel, C, gamma
- **Arbre :** criterion, splitter, max_depth, min_samples…
- **KNN :** n_neighbors, algorithm, p

GitHub : https://github.com/VOTRE-NOM/spacex-capstone/blob/main/SpaceX_Machine_Learning_Prediction_Part_5.ipynb

Résultats

1

Analyse exploratoire

- Le succès augmente avec le nombre de vols et les années
- Les orbites ES-L1, GEO, HEO et SSO ont 100 % de succès
- GTO est l'orbite la plus difficile (52 %)

2

Analytique interactive

- Tous les sites sont près des côtes
- KSC LC-39A a le meilleur taux de succès (76,9 %)
- Les charges de 2 000 à 4 000 kg réussissent le plus souvent

3

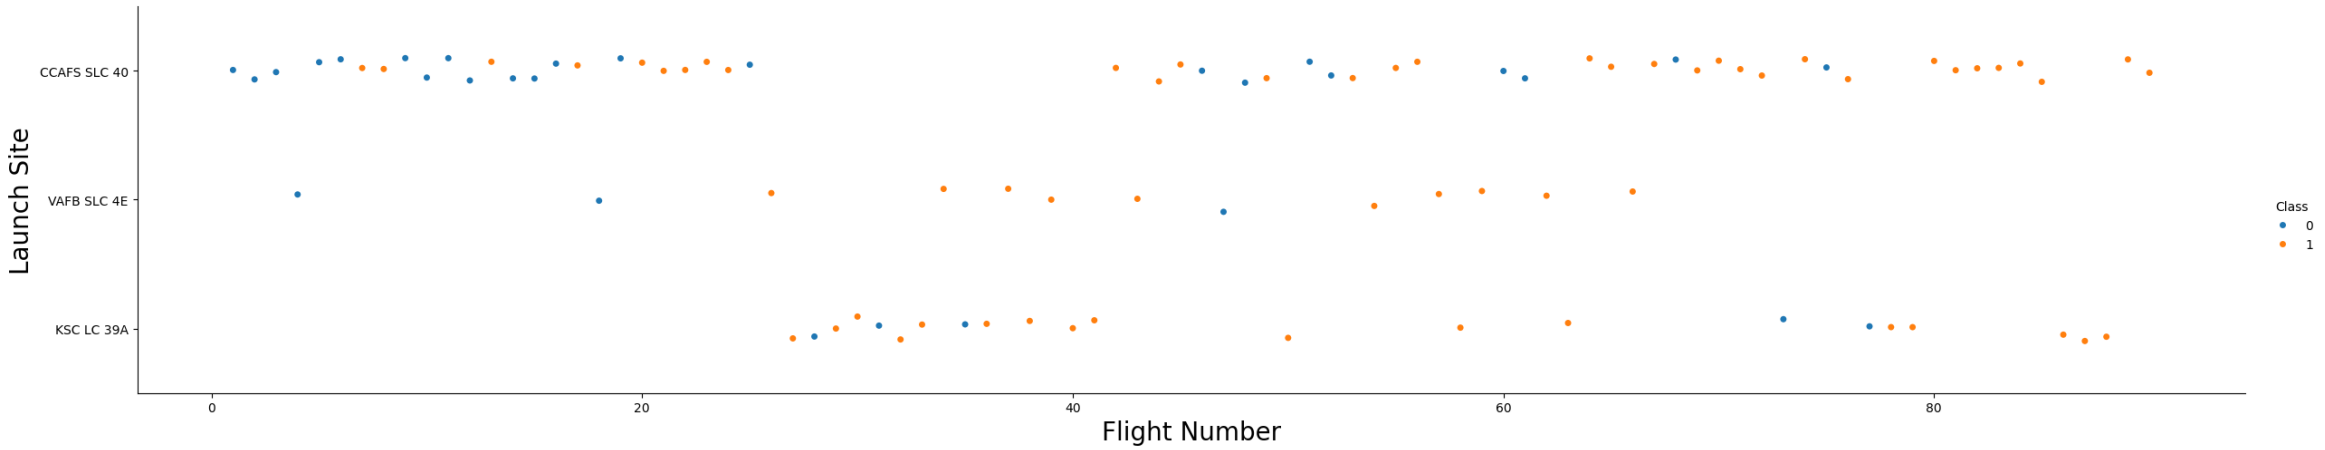
Analyse prédictive

- Les 4 modèles atteignent 83,3 % sur le test
- L'arbre de décision a la meilleure validation croisée (86,3 %)
- Erreurs : 3 faux positifs, aucun faux négatif

Section 2

Enseignements tirés de l'EDA

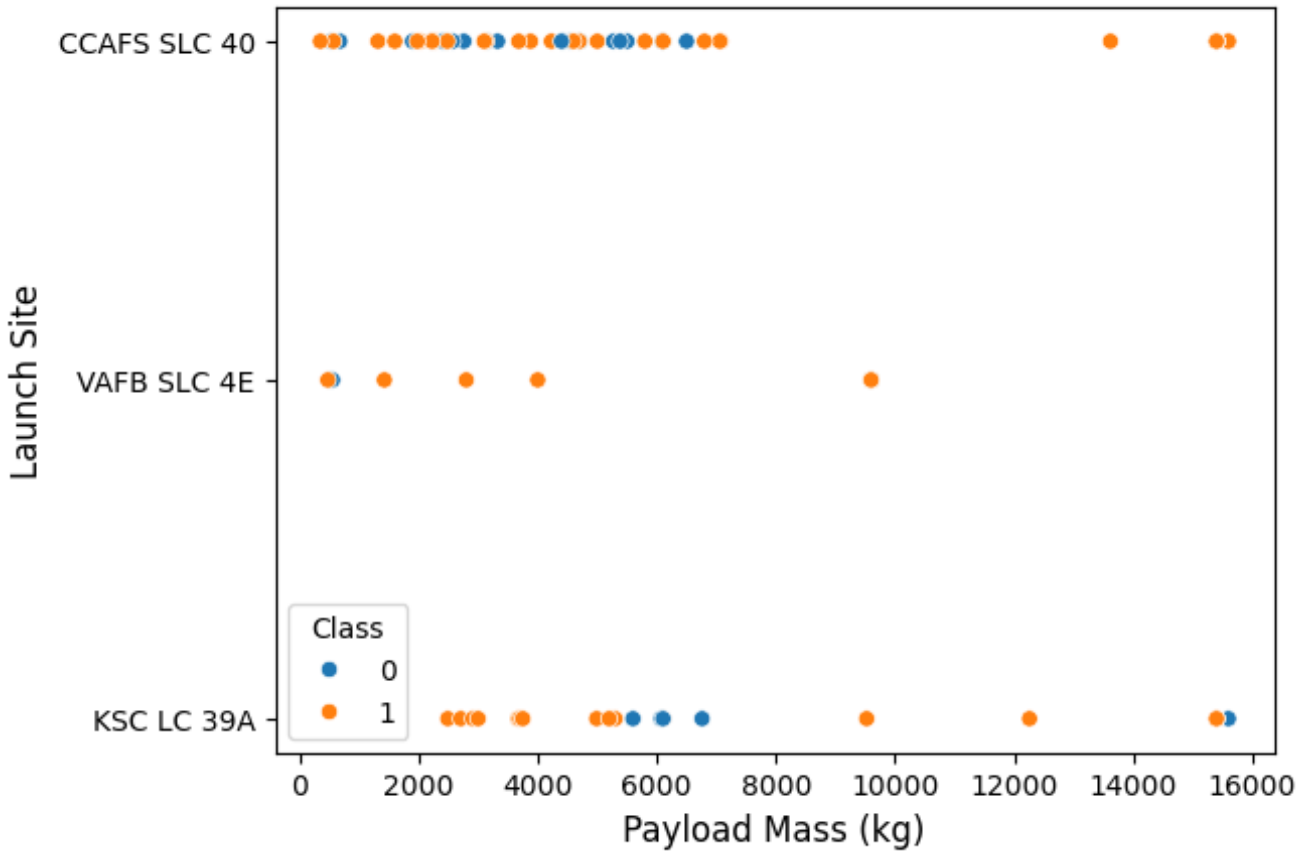
Numéro de vol × site de lancement



Ce que l'on observe

- CCAFS SLC 40 est le site le plus utilisé (55 lancements sur 90)
- Les 25 premiers vols, presque tous à CCAFS, sont surtout des échecs (bleu = 0)
- Plus le numéro de vol augmente, plus les succès (orange = 1) dominent sur tous les sites
- KSC LC 39A n'est utilisé qu'à partir du vol 27 environ

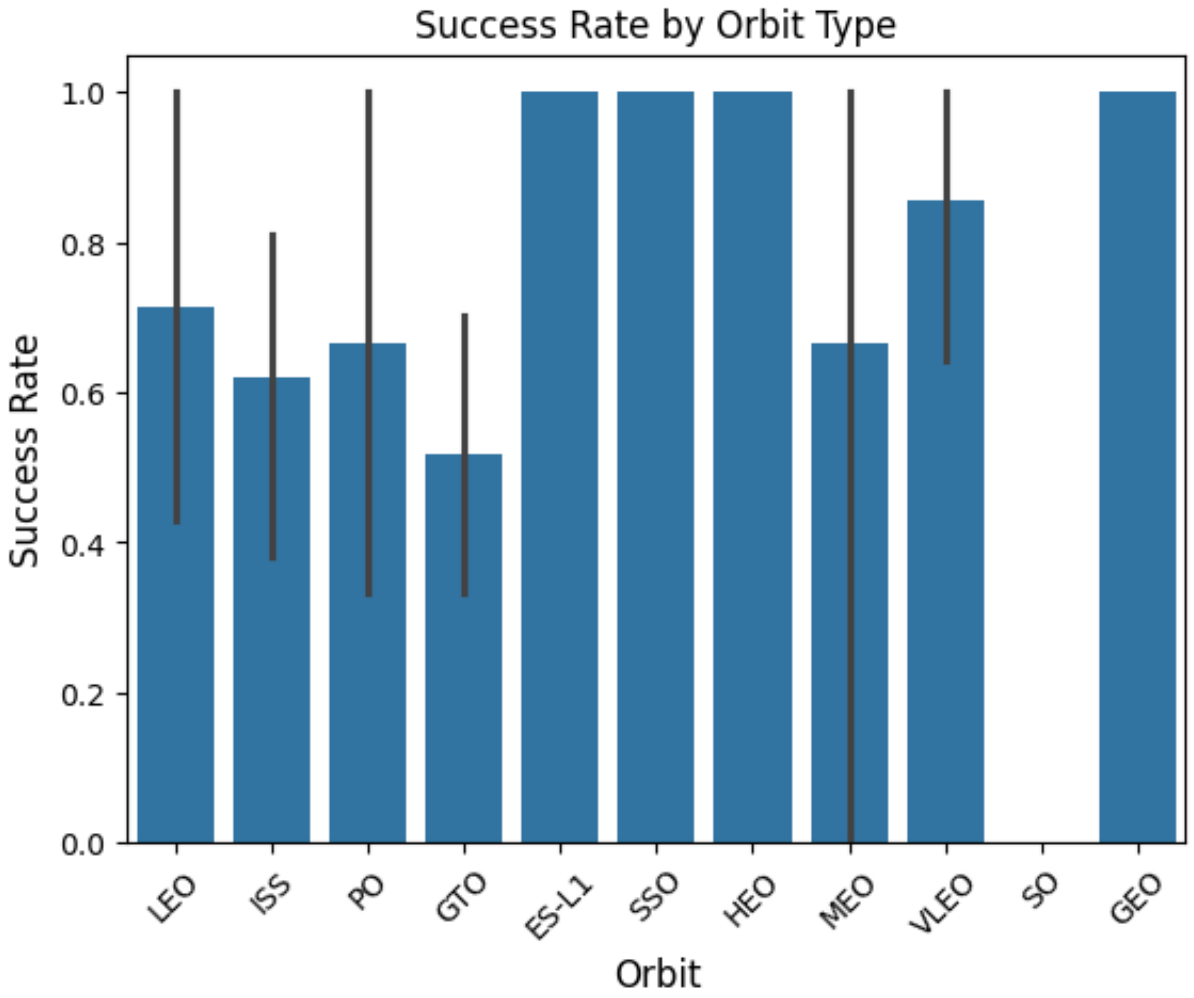
Masse de la charge utile × site de lancement



Ce que l'on observe

- VAFB SLC 4E n'a aucun lancement au-delà de 10 000 kg
- Les charges lourdes (plus de 10 000 kg) réussissent presque toujours, à CCAFS comme à KSC
- Entre 2 000 et 7 000 kg, les résultats sont plus partagés, surtout à CCAFS SLC 40

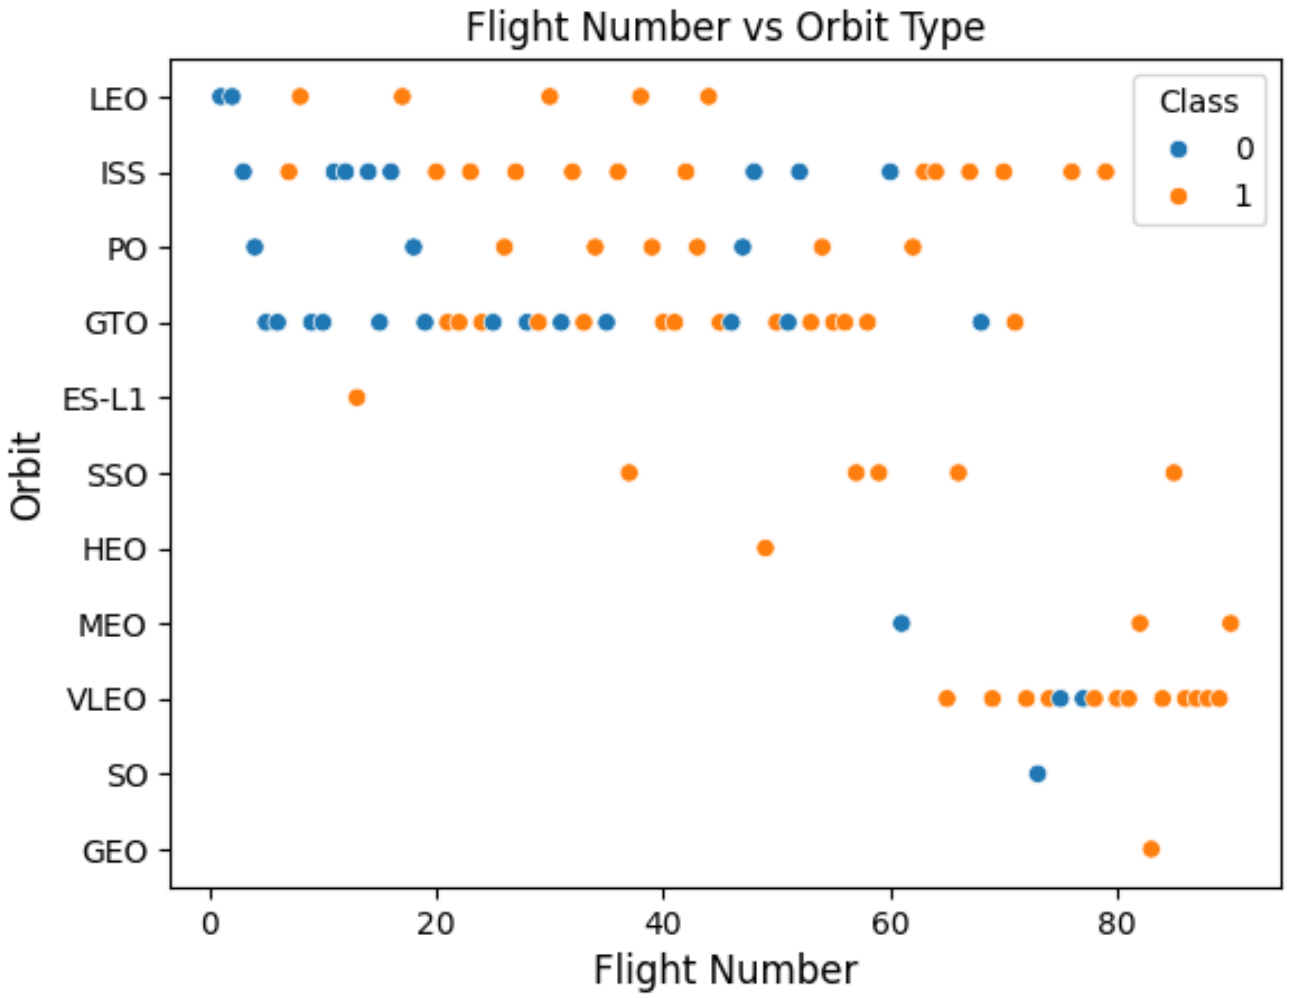
Taux de succès par type d'orbite



Ce que l'on observe

- ES-L1, GEO, HEO et SSO : 100 % de succès (mais 1 à 5 lancements seulement)
- VLEO : 85,7 % sur 14 lancements, un résultat solide
- GTO : 51,9 % sur 27 lancements, l'orbite la plus difficile
- SO : 0 % (un seul lancement)

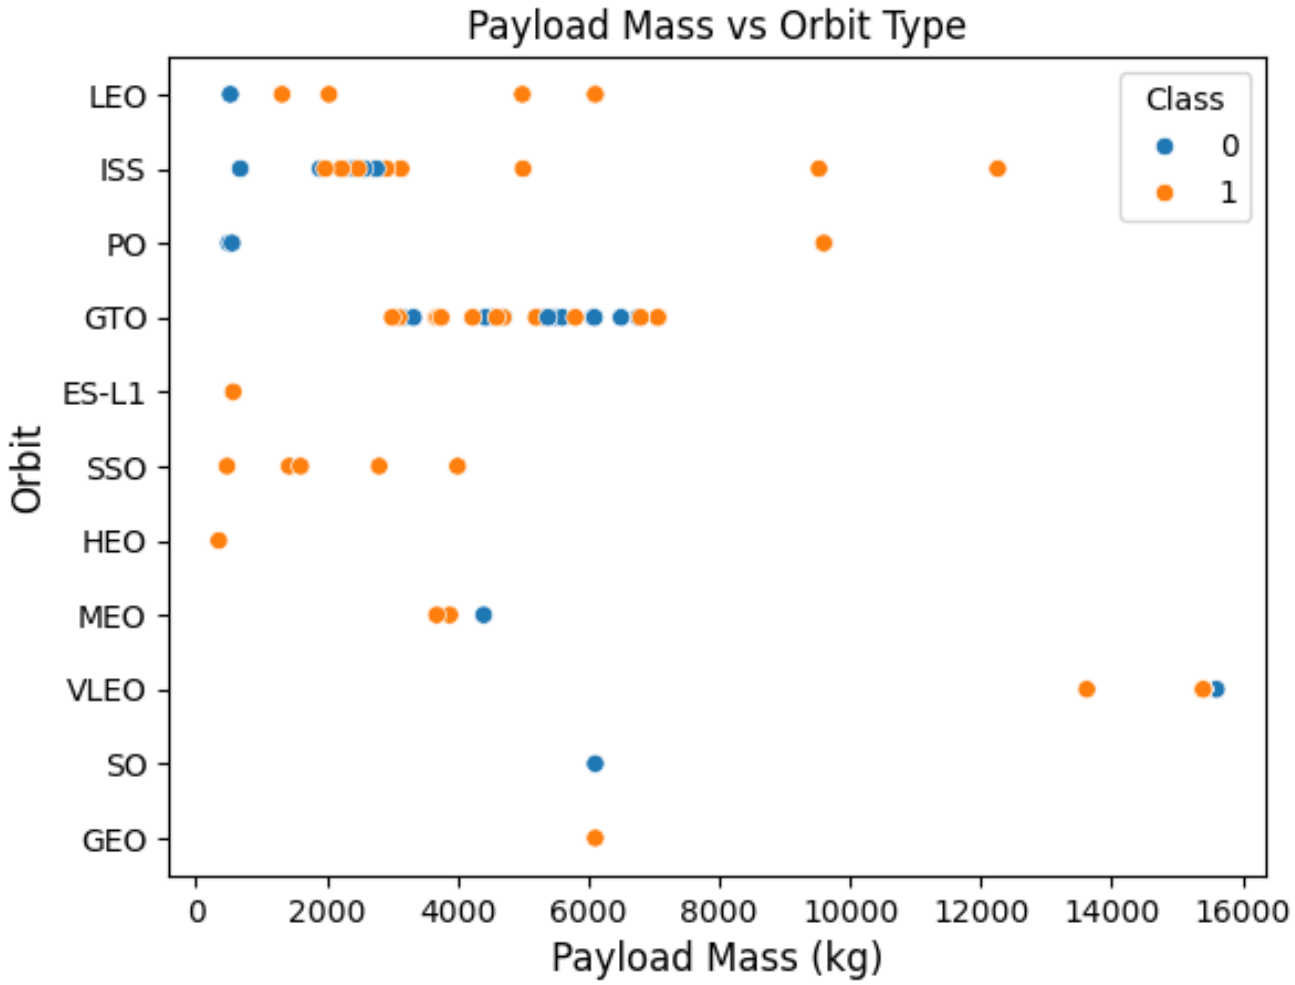
Numéro de vol × type d'orbite



Ce que l'on observe

- En LEO, le succès semble lié au nombre de vols : les échecs sont au début
- En GTO, aucune relation claire avec le numéro de vol
- Les lancements VLEO sont récents et réussissent presque tous

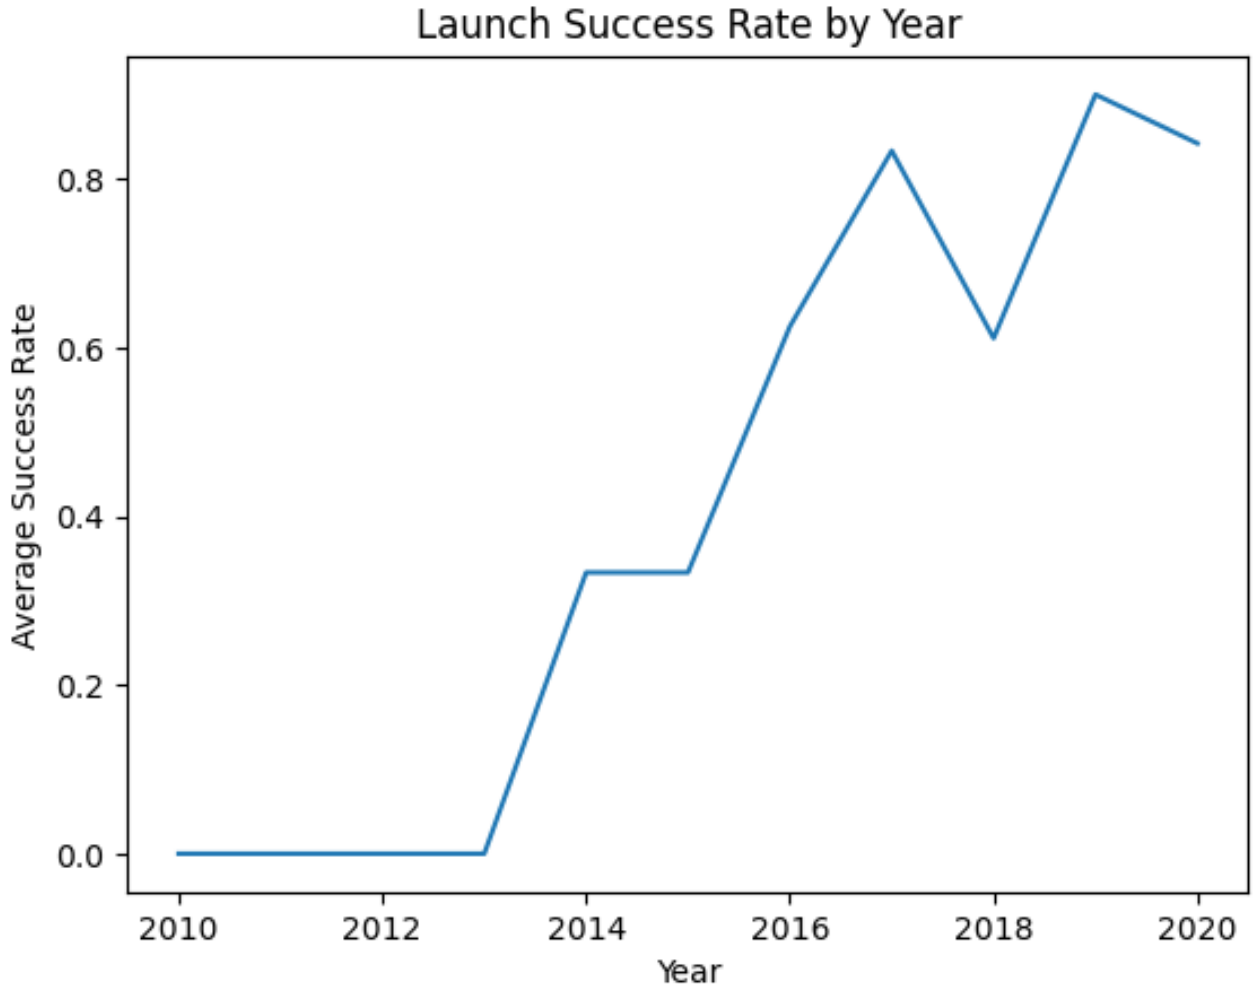
Masse de la charge utile × type d'orbite



Ce que l'on observe

- Les charges lourdes réussissent plus souvent en PO, LEO et ISS
- En GTO, succès et échecs se mélangent quelle que soit la masse (3 000 à 7 000 kg)
- Les très lourdes charges VLEO (13 000 à 16 000 kg) réussissent presque toutes

Tendance annuelle du taux de succès



Ce que l'on observe

- Aucun atterrissage réussi de 2010 à 2013
- Hausse régulière à partir de 2013 : 33 % en 2014, 83 % en 2017
- Baisse ponctuelle en 2018 (61 %), puis un pic à 90 % en 2019
- SpaceX apprend vite : l'expérience améliore nettement la fiabilité

Noms des sites de lancement

Requête

```
SELECT DISTINCT "Launch_Site"
FROM SPACEXTBL;
```

Résultat

Launch_Site
CCAFS LC-40
VAFB SLC-4E
KSC LC-39A
CCAFS SLC-40

Explication : DISTINCT renvoie chaque site une seule fois : SpaceX utilise 4 sites, 3 en Floride et 1 en Californie.

Sites de lancement commençant par « CCA »

```
SELECT * FROM SPACEXTBL
WHERE "Launch_Site" LIKE 'CCA%'
LIMIT 5;
```

Date	Booster	Site	Charge utile	Masse (kg)	Orbite	Client	Atterrissage
2010-06-04	F9 v1.0 B0003	CCAFS LC-40	Dragon Spacecraft Qualification Unit	0	LEO	SpaceX	Failure (parachute)
2010-12-08	F9 v1.0 B0004	CCAFS LC-40	Dragon demo flight C1, two CubeSats, barrel of Brouere cheese	0	LEO (ISS)	NASA (COTS) NRO	Failure (parachute)
2012-05-22	F9 v1.0 B0005	CCAFS LC-40	Dragon demo flight C2	525	LEO (ISS)	NASA (COTS)	No attempt
2012-10-08	F9 v1.0 B0006	CCAFS LC-40	SpaceX CRS-1	500	LEO (ISS)	NASA (CRS)	No attempt
2013-03-01	F9 v1.0 B0007	CCAFS LC-40	SpaceX CRS-2	677	LEO (ISS)	NASA (CRS)	No attempt

Explication : LIKE 'CCA%' garde les sites qui commencent par « CCA » (Cape Canaveral), et LIMIT 5 affiche les 5 premiers. Ce sont les premiers vols, de 2010 à 2013, avec des charges légères.

Masse totale transportée pour la NASA (CRS)

Requête

```
SELECT SUM("PAYLOAD_MASS__KG_")
  AS total_payload_mass
FROM SPACEXTBL
WHERE "Customer" = 'NASA (CRS)';
```

Résultat

45 596 kg

masse totale des charges utiles lancées pour la NASA (CRS)

Explication : SUM additionne la masse de tous les lancements dont le client est NASA (CRS), c'est-à-dire les missions de ravitaillement de l'ISS.

Masse moyenne pour le booster F9 v1.1

Requête

```
SELECT AVG("PAYLOAD_MASS__KG_")
  AS average_payload_mass
FROM SPACEXTBL
WHERE "Booster_Version" = 'F9 v1.1';
```

Résultat

2 928,4 kg

masse moyenne des charges utiles du booster F9 v1.1

Explication : AVG calcule la moyenne des masses pour la version F9 v1.1, une version ancienne aux charges modestes.

Premier atterrissage réussi au sol

Requête

```
SELECT MIN(Date)
  AS first_successful_landing_date
FROM SPACEXTBL
WHERE "Landing_Outcome" =
  'Success (ground pad)';
```

Résultat

22/12/2015

premier atterrissage réussi sur plateforme au sol

Explication : MIN(Date) renvoie la date la plus ancienne parmi les atterrissages réussis au sol : un tournant dans l'histoire de SpaceX.

Succès sur barge avec 4 000 à 6 000 kg

Requête

```
SELECT DISTINCT "Booster_Version"
FROM SPACEXTBL
WHERE "Landing_Outcome" =
  'Success (drone ship)'
  AND "PAYLOAD_MASS__KG_" > 4000
  AND "PAYLOAD_MASS__KG_" < 6000;
```

Résultat

Booster_Version
F9 FT B1022
F9 FT B1026
F9 FT B1021.2
F9 FT B1031.2

Explication : Les conditions combinées avec AND filtrent les atterrissages réussis sur barge avec une charge entre 4 000 et 6 000 kg. Les 4 boosters sont de la version FT.

Nombre de missions réussies et échouées

Requête

```
SELECT "Mission_Outcome",
  COUNT(*) AS total
FROM SPACEXTBL
GROUP BY "Mission_Outcome";
```

Résultat

Mission_Outcome	Total
Success	98
Success (avec espace en trop)	1
Success (payload status unclear)	1
Failure (in flight)	1

Explication : GROUP BY compte les missions par résultat : 100 missions réussies sur 101. Attention, il s'agit de la mission (mise en orbite), pas de l'atterrissage du premier étage.

Boosters ayant porté la charge maximale

Requête

```
SELECT "Booster_Version"
FROM SPACEXTBL
WHERE "PAYLOAD_MASS__KG_" = (
  SELECT MAX("PAYLOAD_MASS__KG_")
  FROM SPACEXTBL
);
```

Résultat

Booster	Booster
F9 B5 B1048.4	F9 B5 B1049.5
F9 B5 B1049.4	F9 B5 B1060.2
F9 B5 B1051.3	F9 B5 B1058.3
F9 B5 B1056.4	F9 B5 B1051.6
F9 B5 B1048.5	F9 B5 B1060.3
F9 B5 B1051.4	F9 B5 B1049.7

Explication : La sous-requête trouve la masse maximale, puis la requête principale liste les boosters qui l'ont portée. Les 12 sont des Block 5, la version la plus récente.

Échecs sur barge en 2015

Requête

```
SELECT substr(Date, 6, 2) AS month,
  "Landing_Outcome",
  "Booster_Version", "Launch_Site"
FROM SPACEXTBL
WHERE substr(Date, 0, 5) = '2015'
  AND "Landing_Outcome" =
  'Failure (drone ship)';
```

Résultat

Mois	Booster	Site
01 (janvier)	F9 v1.1 B1012	CCAFS LC-40
04 (avril)	F9 v1.1 B1015	CCAFS LC-40

Explication : SQLite n'a pas de fonction pour le nom du mois, on utilise substr() pour extraire le mois et l'année. En 2015, deux tentatives sur barge ont échoué, toutes deux avec des F9 v1.1.

Classement des résultats d'atterrissage (2010-2017)

Requête

```
SELECT "Landing_Outcome",
  COUNT(*) AS outcome_count
FROM SPACEXTBL
WHERE Date BETWEEN '2010-06-04'
  AND '2017-03-20'
GROUP BY "Landing_Outcome"
ORDER BY outcome_count DESC;
```

Résultat

Landing_Outcome	Nombre
No attempt	10
Success (drone ship)	5
Failure (drone ship)	5
Success (ground pad)	3
Controlled (ocean)	3
Uncontrolled (ocean)	2
Failure (parachute)	2
Precluded (drone ship)	1

Explication : Sur cette période, l'absence de tentative est le cas le plus fréquent. Les atterrissages sur barge sont aussi souvent réussis qu'échoués (5 contre 5).

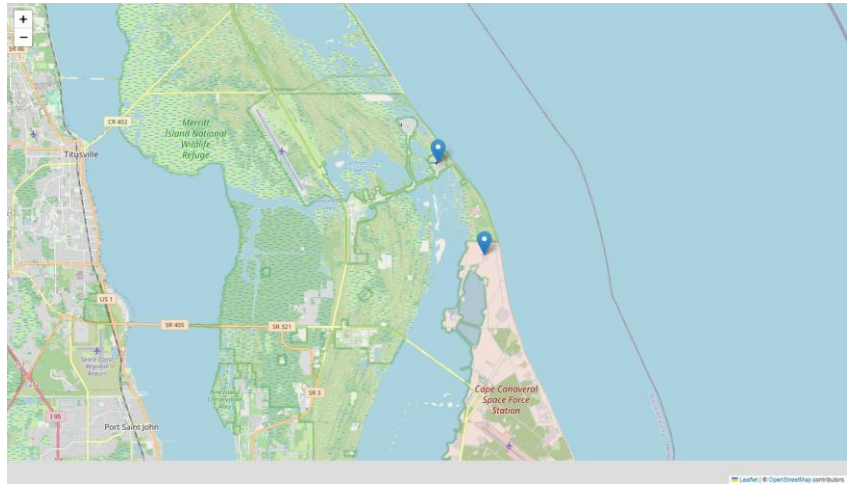
Section 3

Analyse de proximité des sites de lancement

Carte de tous les sites de lancement



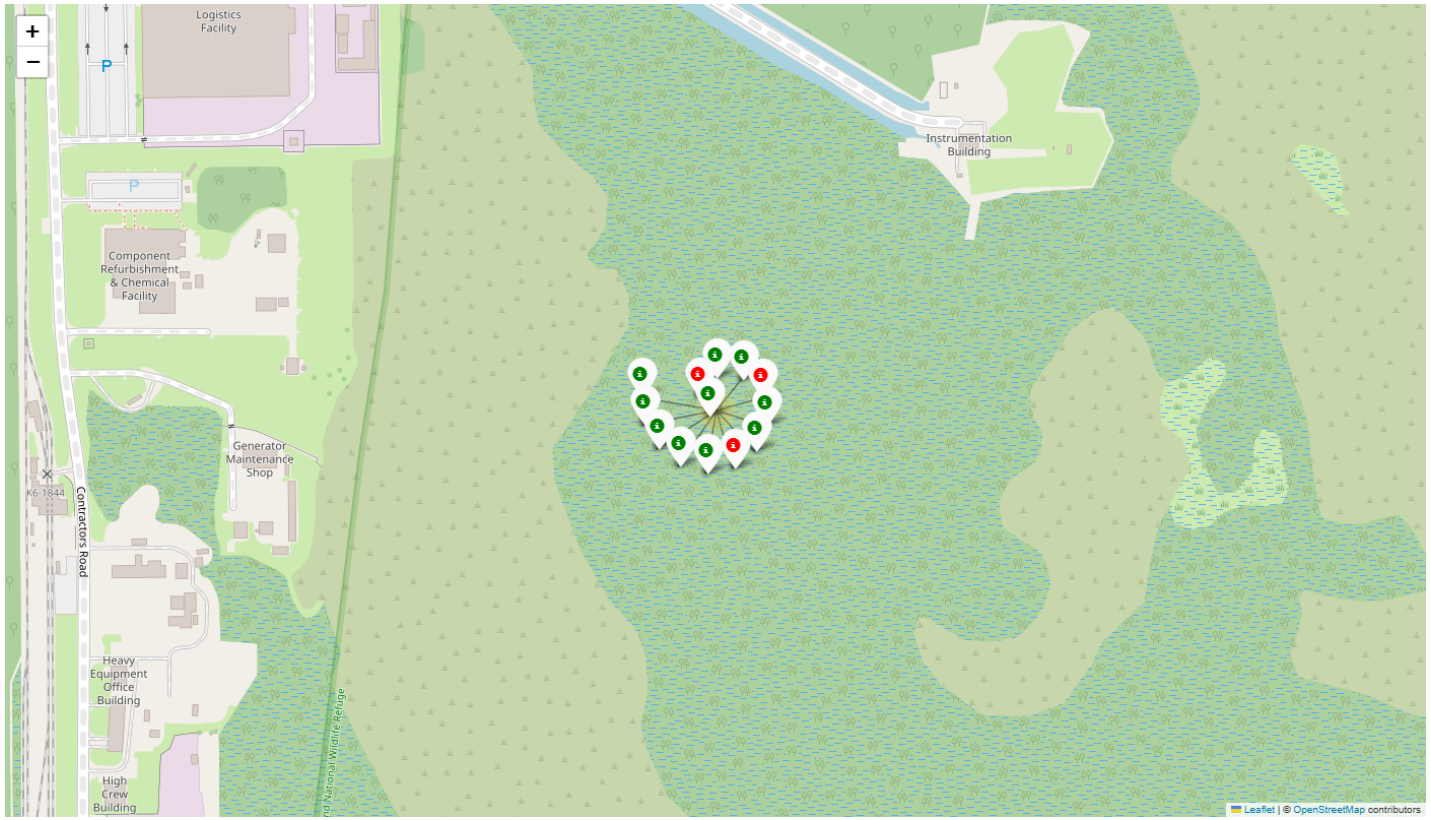
Vue d'ensemble des 4 sites de lancement



Zoom sur les 3 sites de Floride

- 4 sites : 3 en Floride et 1 en Californie (VAFB SLC-4E)
- Tous en bord de mer : les étages et débris retombent dans l'océan
- La Floride, proche de l'équateur, profite de la rotation terrestre

Succès et échecs par site sur la carte

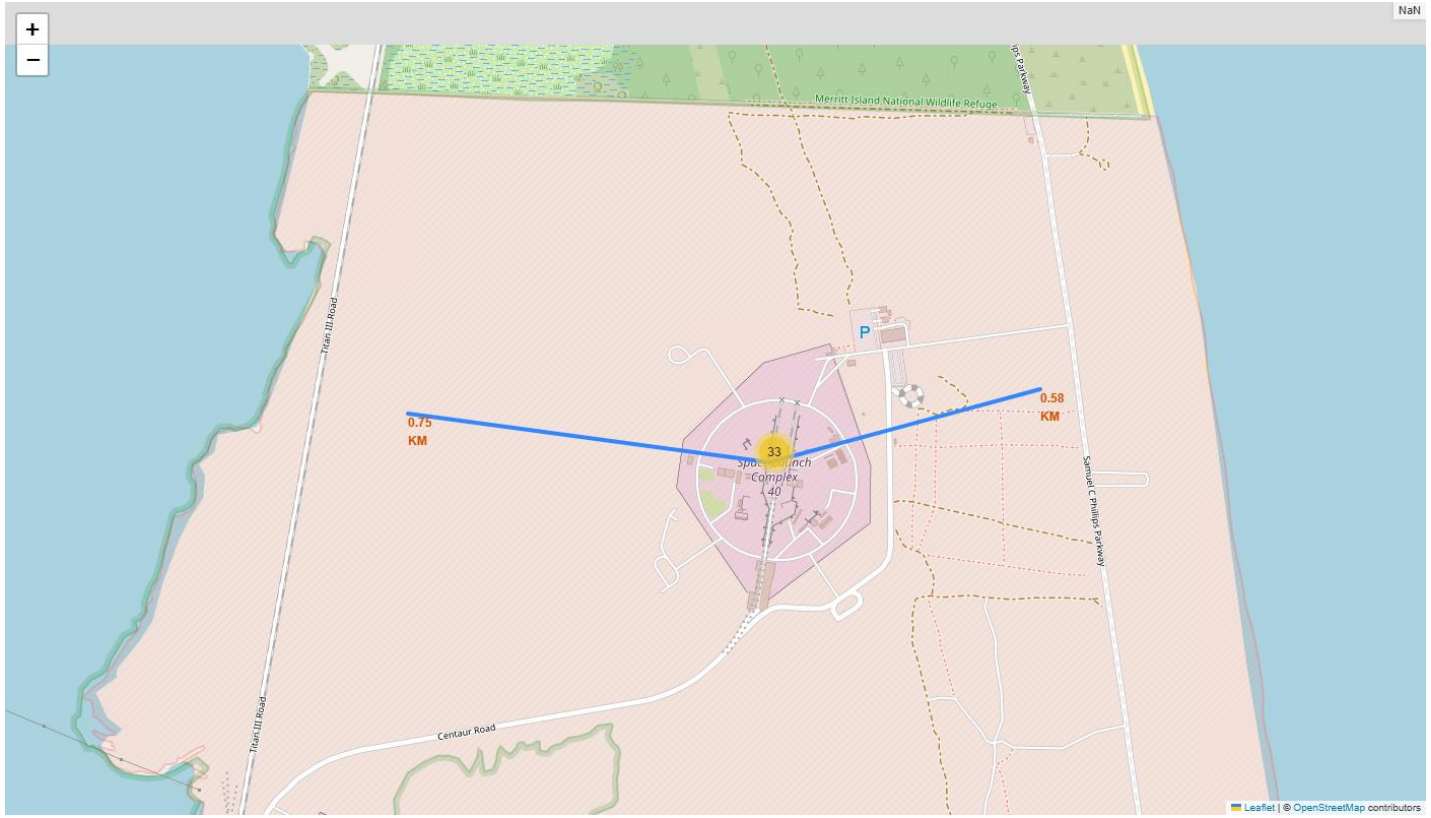


KSC LC-39A : cluster ouvert (vert = succès, rouge = échec)

Site	Lancements	Succès	Taux
KSC LC-39A	13	10	76,9 %
CCAFS SLC-40	7	3	42,9 %
VAFB SLC-4E	10	4	40,0 %
CCAFS LC-40	26	7	26,9 %

Les marqueurs colorés montrent en un coup d'œil que KSC LC-39A réussit le plus souvent : 10 marqueurs verts sur 13.

Proximité de CCAFS SLC-40 avec son environnement



Lignes tracées avec PolyLine et distances calculées avec la formule de Haversine

0,58 km
jusqu'à la côte

0,75 km
jusqu'à une route du site

23 km
jusqu'à Titusville, la ville la plus proche

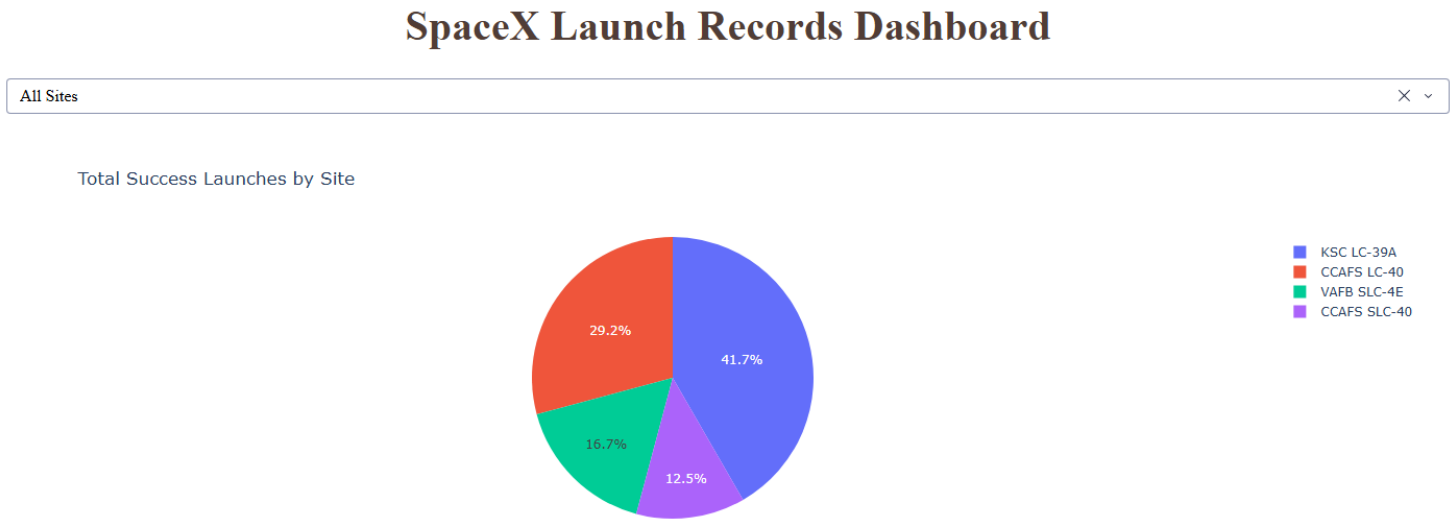
78 km
jusqu'à Orlando

Les sites sont très proches de la côte et des routes (logistique) mais éloignés des villes, pour protéger la population en cas d'échec.

Section 4

Dashboard avec Plotly Dash

Part des lancements réussis par site

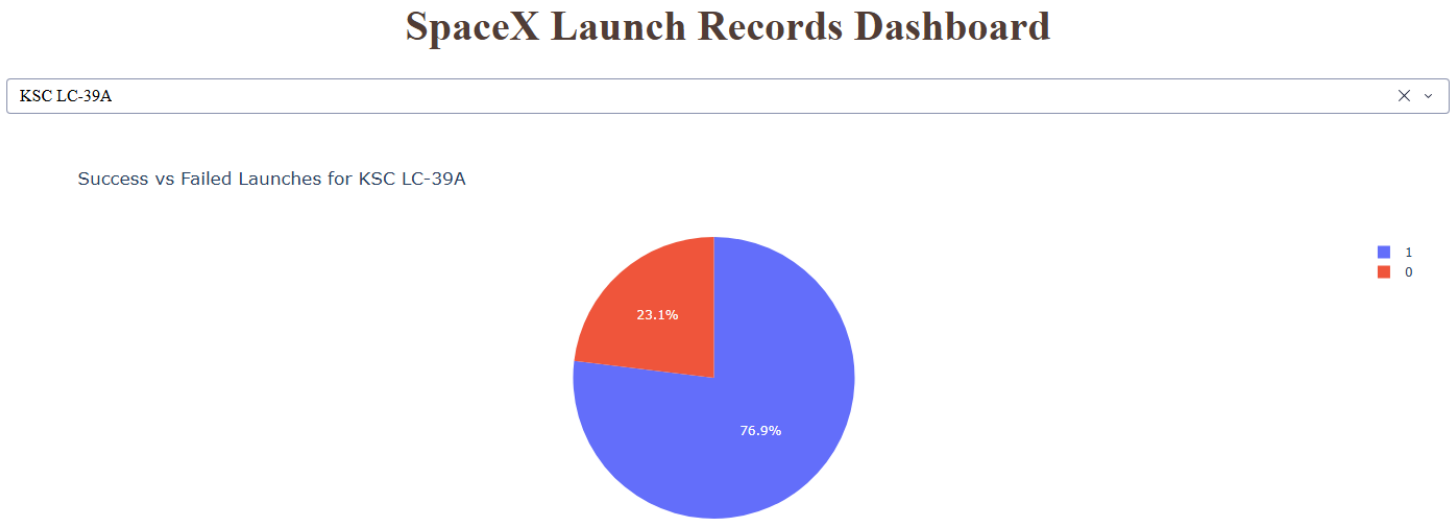


Option « All Sites » sélectionnée : la valeur du camembert est la somme de Class par site.

Ce que l'on observe

- KSC LC-39A représente 41,7 % de tous les succès, la plus grande part
- Viennent ensuite CCAFS LC-40 (29,2 %), VAFB SLC-4E (16,7 %) et CCAFS SLC-40 (12,5 %)
- CCAFS LC-40 a beaucoup de lancements mais un taux de succès plus faible

KSC LC-39A, le site le plus performant



Une fois KSC LC-39A choisi dans la liste, le camembert montre succès et échecs pour ce site seulement.

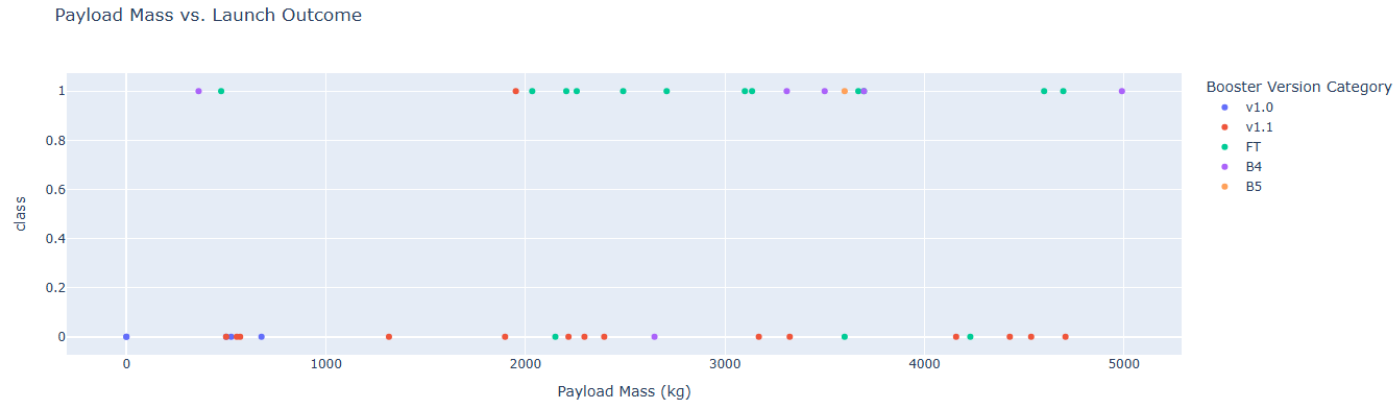
76,9 %

de succès (10 lancements sur 13), en bleu (Class = 1)

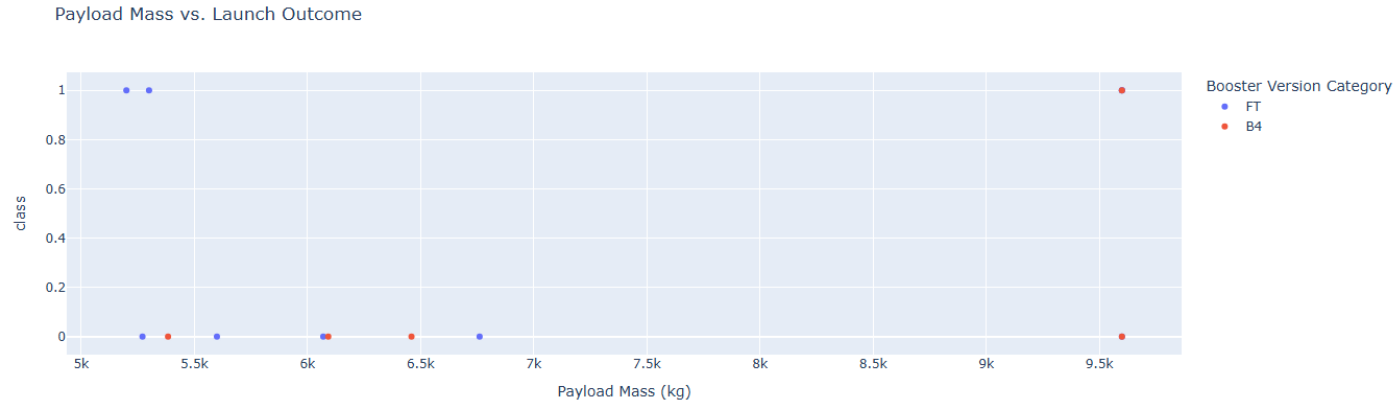
23,1 %

d'échecs (3 lancements), en rouge (Class = 0)

Charge utile × résultat pour tous les sites



Curseur réglé sur 0 – 5 000 kg



Curseur réglé sur 5 000 – 10 000 kg

Charge utile	Taux de succès
0 – 2 000 kg	23 %
2 000 – 4 000 kg	62 %
4 000 – 6 000 kg	38 %
6 000 – 10 000 kg	33 %

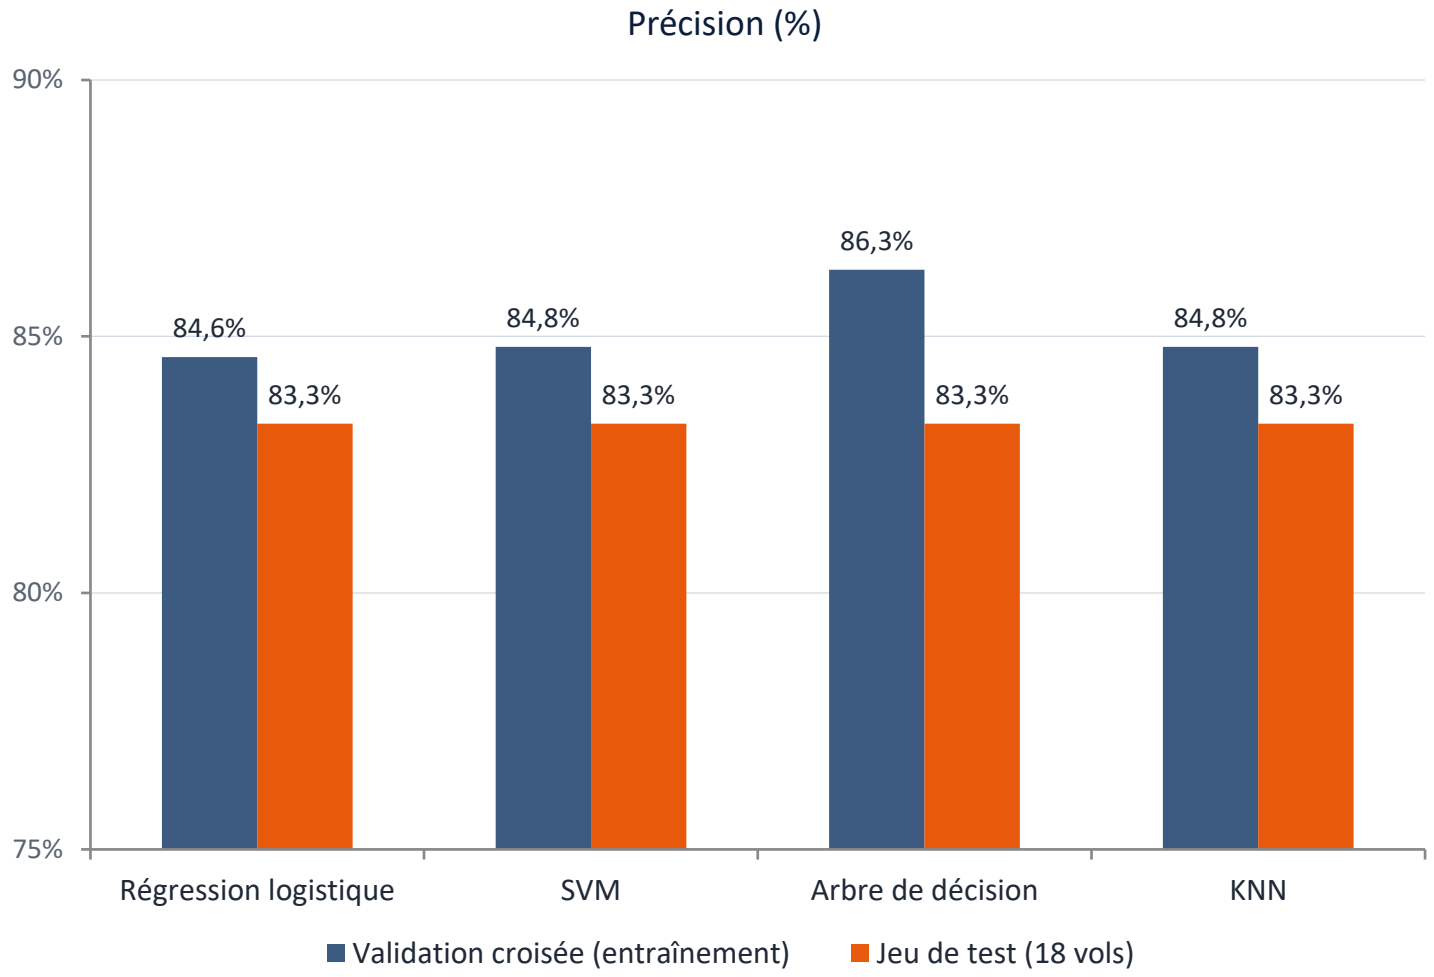
Ce que l'on observe

- Les charges de 2 000 à 4 000 kg réussissent le mieux
- Le booster FT réussit le mieux (67 % sur 24 vols) ; v1.1 presque jamais (7 % sur 15)

Section 5

Analyse prédictive (classification)

Précision des modèles de classification

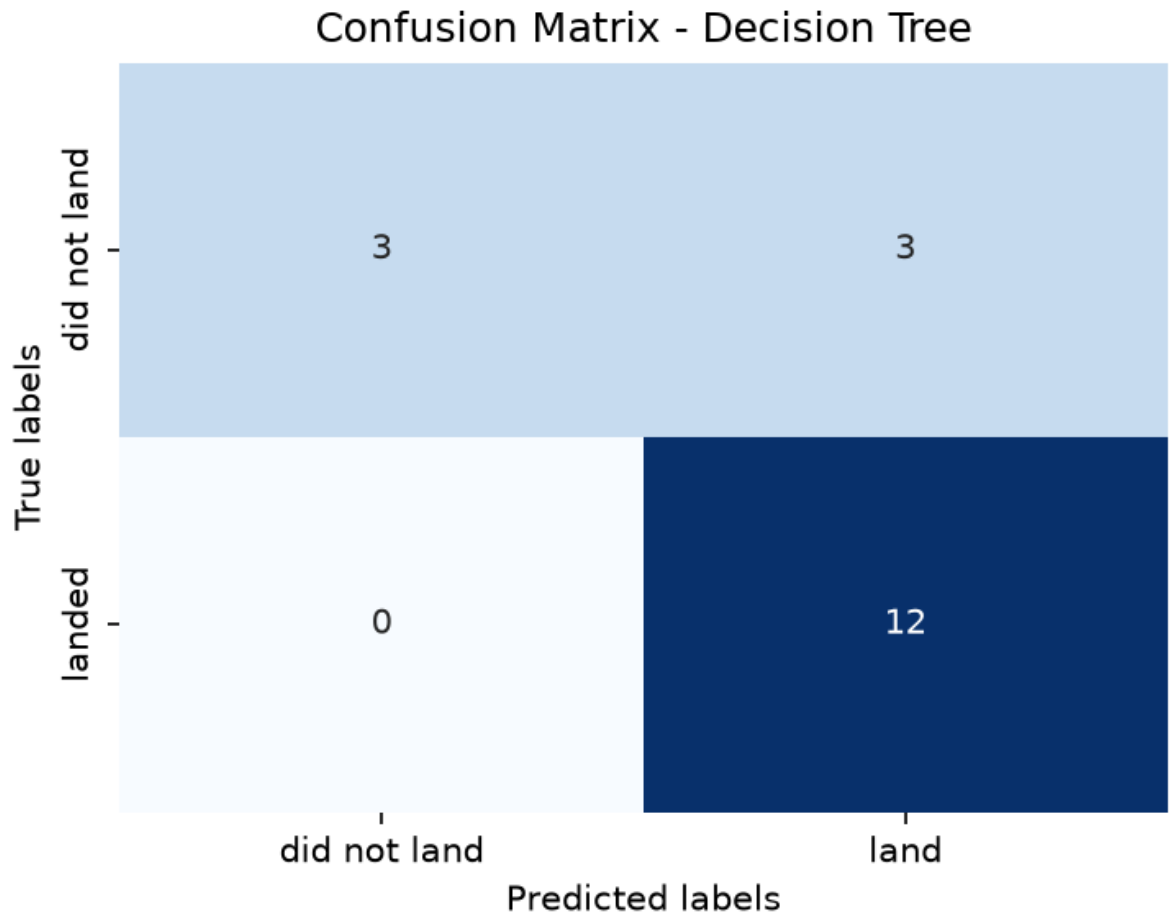


86,3 %

précision en validation croisée de l'arbre de décision, la meilleure

- Sur le test, les 4 modèles font jeu égal : 83,3 % (15 vols sur 18)
- On retient donc l'arbre de décision : max_depth = 6, critère gini
- Le test est petit (18 vols) : les écarts restent faibles

Matrice de confusion du meilleur modèle



Lecture de la matrice

- **Vrais positifs :** 12 atterrissages bien prédits
- **Vrais négatifs :** 3 échecs bien prédits
- **Faux positifs :** 3 échecs prédits à tort comme réussis
- **Faux négatifs :** 0
- Le modèle repère tous les succès ; sa faiblesse, ce sont les faux positifs. Les 4 modèles ont exactement la même matrice sur le test.

Conclusion

- **Expérience :** le taux de succès passe de 0 % (2010-2013) à 90 % (2019). Plus SpaceX vole, plus elle réussit
- **Site :** KSC LC-39A a le meilleur taux de succès (76,9 %) ; tous les sites sont près des côtes et loin des villes
- **Orbite :** ES-L1, GEO, HEO, SSO et VLEO réussissent le mieux ; GTO reste la plus difficile (52 %)
- **Charge utile :** 2 000 à 4 000 kg est la plage la plus favorable ; le booster FT surpasse les anciennes versions
- **Modèle :** l'arbre de décision est retenu (86,3 % en validation croisée, 83,3 % sur le test). Il permet d'estimer si le premier étage sera récupéré, donc le coût d'un lancement

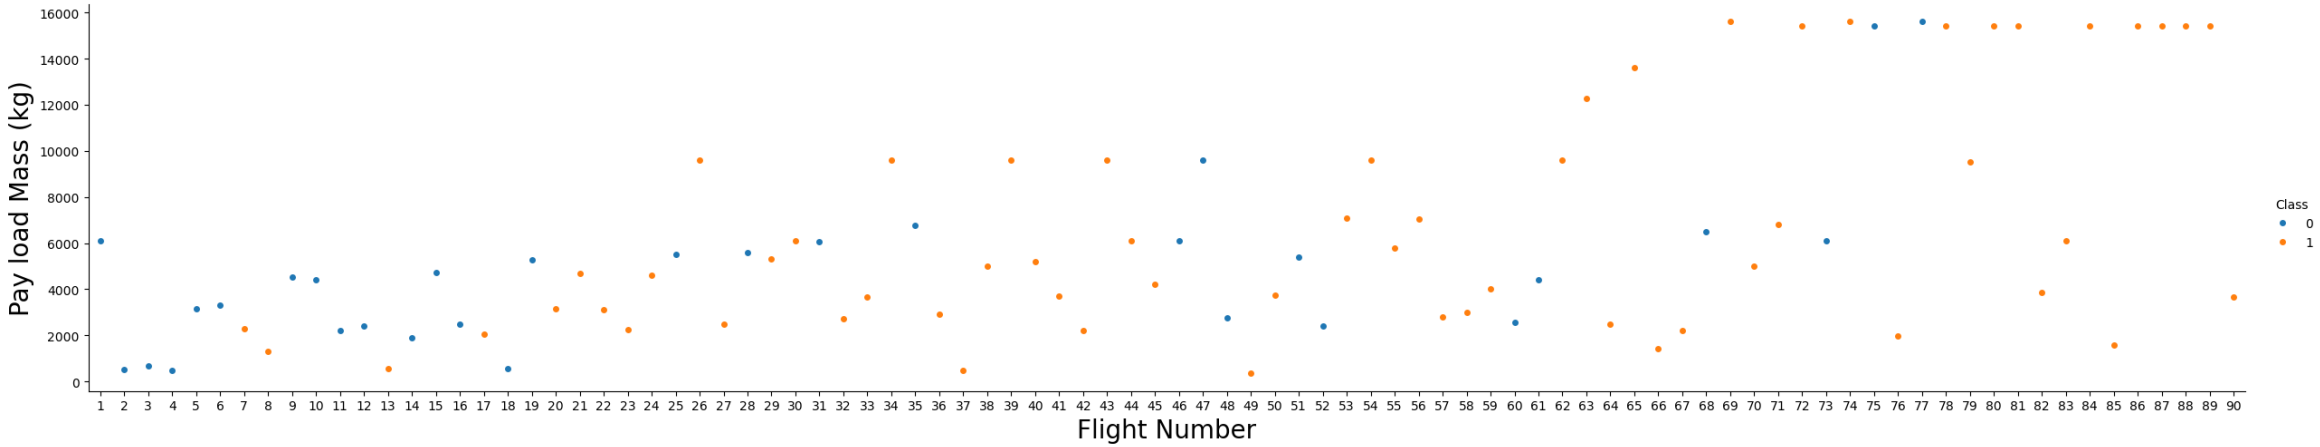
Idées pour aller plus loin

- **Outil d'enchère pour Space Y :** coût estimé = probabilité d'atterrissage × économie de réutilisation
- **Plus de données :** lancements après 2020, météo, nombre de réutilisations du booster
- **Modèles plus robustes :** forêt aléatoire, XGBoost, mesures F1 et ROC-AUC
- **Prédiction en direct :** ajouter le modèle au dashboard Dash

Annexe

Graphiques complémentaires

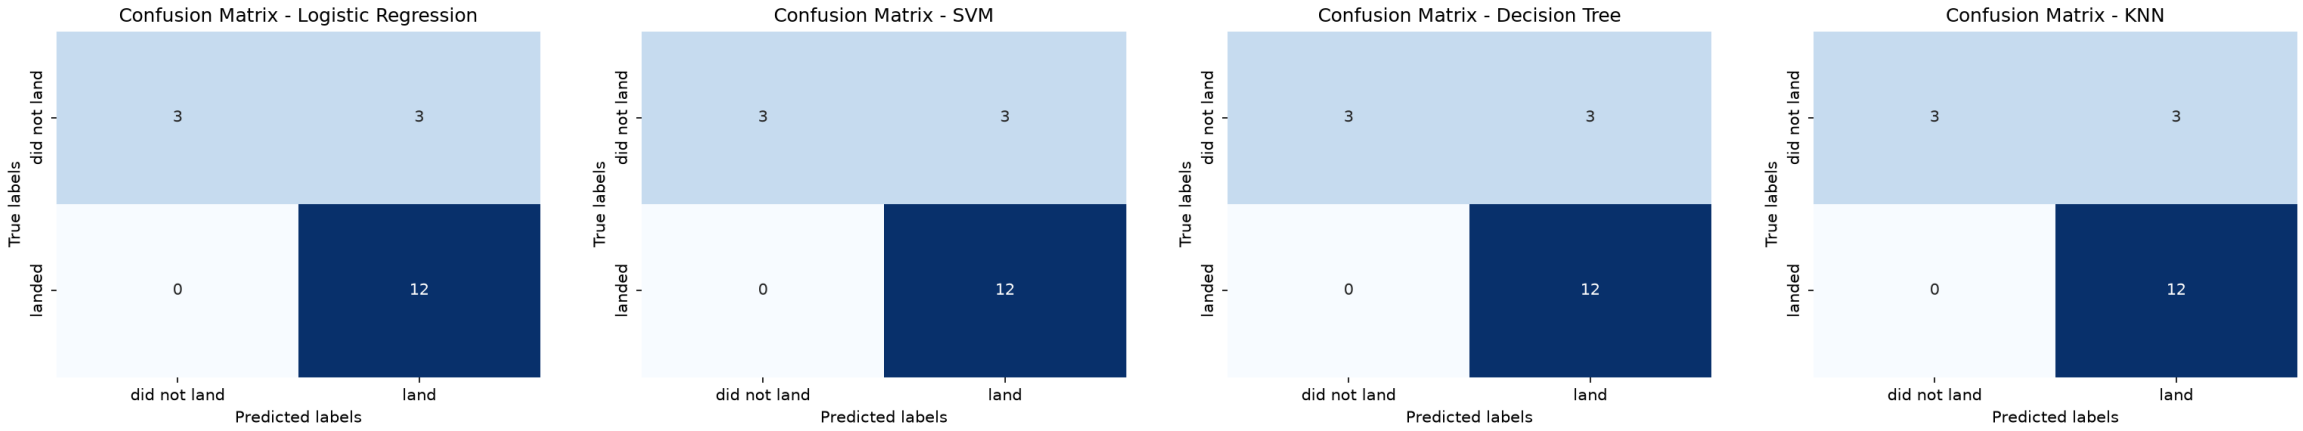
Annexe — Numéro de vol × masse de la charge utile



Ce que l'on observe

- Plus le numéro de vol augmente, plus le premier étage atterrit avec succès
- Les charges lourdes ne sont pas un obstacle pour les vols récents

Annexe — Matrices de confusion des 4 modèles



Les 4 modèles produisent la même matrice sur le jeu de test : 12 vrais positifs, 3 vrais négatifs, 3 faux positifs et 0 faux négatif.

GitHub : https://github.com/VOTRE-NOM/spacex-capstone/blob/main/SpaceX_Machine_Learning_Prediction_Part_5.ipynb